

UNIVERSIDADE DE SÃO PAULO

Instituto de Ciências Matemáticas e de Computação

Análise Filogenética e Modelagem Estrutural para Otimização da Produção Agrícola

Jose Luis Juarez Ruelas

Qualificação de Doutorado do Programa de Pós-Graduação em Ciências de Computação e Matemática Computacional (PPG-CCMC)

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Jose Luis Juarez Ruelas

Análise Filogenética e Modelagem Estrutural para Otimização da Produção Agrícola

Monografia apresentada ao Instituto de Ciências Matemáticas e de Computação – ICMC-USP, para o Exame de Qualificação, como parte dos requisitos para obtenção do título de Doutor em Ciências – Ciências de Computação e Matemática Computacional.

Área de Concentração: Ciências de Computação e Matemática Computacional

Orientador: Prof. Dr. Alexandre Cláudio Botazzo Delbem

**USP – São Carlos
Fevereiro de 2025**

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi
e Seção Técnica de Informática, ICMC/USP,
com os dados inseridos pelo(a) autor(a)

J921a Juarez Ruelas, Jose Luis
 Análise Filogenética e Modelagem Estrutural para
Otimização da Produção Agrícola / Jose Luis Juarez
Ruelas; orientador Alexandre Cláudio Botazzo
Delbem. -- São Carlos, 2025.
 96 p.

 Tese (Doutorado - Programa de Pós-Graduação em
Ciências de Computação e Matemática Computacional) --
Instituto de Ciências Matemáticas e de Computação,
Universidade de São Paulo, 2025.

 1. Análise filogenética. 2. Blocos de construção.
3. Critério de complexidade combinada. 4. Dados
heterogêneos. 5. Produção agrícola. I. Botazzo
Delbem, Alexandre Cláudio, orient. II. Título.

Jose Luis Juarez Ruelas

**Phylogenetic Analysis and Structural Modeling for
Optimization of Agricultural Production**

Monograph submitted to the Instituto de Ciências Matemáticas e de Computação – ICMC-USP – as part of the qualifying exam requisites of the Computer and Mathematical Sciences Graduate Program, for the degree of Doctor in Science.

Concentration Area: Computer Science and Computational Mathematics

Advisor: Prof. Dr. Alexandre Cláudio Botazzo Delbem

USP – São Carlos
February 2025

RESUMO

RUELAS, J. L. J. **Análise Filogenética e Modelagem Estrutural para Otimização da Produção Agrícola**. 2025. 98 p. Monografia (Doutorado em Ciências – Ciências de Computação e Matemática Computacional) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2025.

Os sistemas agrícolas modernos demandam métodos de inferência robustos e explicáveis para apoiar a tomada de decisão, sobretudo quando se trata da transportabilidade dos modelos em cenários diversos de produção. A complexidade e a heterogeneidade dos dados, aliadas à necessidade de revelar relações causais subjacentes, impõem desafios significativos à modelagem tradicional, limitando a aplicabilidade prática dos modelos desenvolvidos. Este estudo tem como objetivo obter melhores modelos a partir de dados que beneficiem a inferência e a tomada de decisão. Para isso, propõe-se o desenvolvimento de modelos estruturais que favoreçam a explicabilidade e a verificação de relações causais, aspectos essenciais para a transportabilidade dos modelos em diferentes contextos agrícolas. Para enfrentar esses desafios, foi elaborada uma metodologia que integra análise filogenética e o Critério de Complexidade Combinada (CCC). A abordagem filogenética utiliza quatro métodos (SM1, SM2, SM3 e SM4) para gerar filogramas que identificam subconjuntos relevantes de variáveis. Paralelamente, o CCC—fundamentado no Modelo de Produto Marginal e no Princípio do Comprimento Mínimo de Descrição—estrutura blocos de construção e forma partições otimizadas, possibilitando a redução da dimensionalidade dos dados sem prejuízo da precisão dos modelos. O conjunto de dados fornecido pela Fundação ABC, raro e abrangente, permite explorar esses modelos estruturais e avaliar aspectos de sua transportabilidade em sistemas agrícolas. A aplicação da metodologia demonstrou que a interseção entre as variáveis destacadas pelos filogramas e os agrupamentos definidos pelo CCC permitiu identificar fatores determinantes da produtividade da soja, tais como condições agrometeorológicas, características de altitude, práticas de manejo e características genotípicas. Os modelos desenvolvidos apresentaram elevada interpretabilidade e potencial para inferir relações causais, evidenciando sua capacidade de serem transportados para diferentes cenários de produção agrícola. A integração entre análise filogenética e o CCC constitui uma estratégia promissora para a obtenção de modelos estruturais que aprimoram a inferência e a tomada de decisão em sistemas agrícolas. A explicabilidade e a verificação das relações causais desses modelos reforçam sua transportabilidade, um aspecto vital para sua aplicação prática em múltiplos contextos agrícolas. Ademais, o conjunto de dados raro da Fundação ABC contribui significativamente para validar a abordagem proposta, evidenciando seu potencial de transformação na prática da produção agrícola e em outros domínios que lidam com grandes volumes de dados heterogêneos.

Palavras-chave: Análise filogenética, Blocos de construção, Critério de complexidade combinada, Dados heterogêneos, Produção agrícola.

ABSTRACT

RUELAS, J. L. J. **Phylogenetic Analysis and Structural Modeling for Optimization of Agricultural Production**. 2025. 98 p. Monografia (Doutorado em Ciências – Ciências de Computação e Matemática Computacional) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2025.

Modern agricultural systems require robust and explainable inference methods to support decision-making, particularly when it comes to the transportability of models across diverse production scenarios. The complexity and heterogeneity of data, coupled with the need to uncover underlying causal relationships, pose significant challenges to traditional modeling approaches, limiting the practical applicability of the developed models. This study aims to obtain better models from data that enhance inference and decision-making. To achieve this, the development of structural models that promote explainability and the verification of causal relationships is proposed, as these aspects are essential for the transportability of models across different agricultural contexts. To address these challenges, a methodology was designed that integrates phylogenetic analysis and the Combined Complexity Criterion (CCC). The phylogenetic approach employs four methods (SM1, SM2, SM3, and SM4) to generate phylograms that identify relevant subsets of variables. In parallel, the CCC—based on the Marginal Product Model and the Minimum Description Length Principle—structures building blocks and forms optimized partitions, enabling the reduction of data dimensionality without compromising model accuracy. The comprehensive and rare dataset provided by Fundação ABC allows for the exploration of these structural models and the evaluation of their transportability in agricultural systems. The application of the methodology demonstrated that the intersection between the variables highlighted by the phylograms and the groupings defined by the CCC identified key determinants of soybean productivity, such as agrometeorological conditions, altitude characteristics, management practices, and genotypic traits. The developed models exhibited high interpretability and potential for inferring causal relationships, demonstrating their ability to be transported across different agricultural production scenarios. The integration of phylogenetic analysis and the CCC constitutes a promising strategy for obtaining structural models that enhance inference and decision-making in agricultural systems. The explainability and verification of causal relationships in these models reinforce their transportability, a vital aspect for their practical application in multiple agricultural contexts. Furthermore, the rare dataset from Fundação ABC significantly contributes to validating the proposed approach, highlighting its transformative potential in agricultural production practices and in other domains dealing with large volumes of heterogeneous data.

Keywords: Phylogenetic analysis, Building blocks, Combined complexity criterion, Heterogeneous data, Agricultural production.

LISTA DE ILUSTRAÇÕES

Figura 1 – Distribuição dos estudos primários (fase de condução)	27
Figura 2 – Distribuição de Estudos por Base de Dados	29
Figura 3 – Nuvem de Palavras: Frequência de Termos em Títulos e Resumos	30
Figura 4 – Etapas do Processo da Pesquisa	34
Figura 5 – Fluxo das Etapas NCD, NJ e FN do DAMICORE	38
Figura 6 – Fluxo para Construção de Categorias Baseadas no Ranqueamento do Objetivo	41
Figura 7 – Fluxo do DAMICORE por Partição: Geração dos Filogramas	42
Figura 8 – Lista Baseada em Clados: $p1i$ ($p2i$) representa os Clados do Best e Worst Model Superior (Inferior). $s1i = \{A, B\}$ ($s2i = \{\}$), Resultando em $sclade = \{A, B\}$	43
Figura 9 – Listas Baseadas em Critérios: Subárvores destacadas em azul com Nó A como Alvo. $sriterion = \{A, B, C\}$	44
Figura 10 – Lista Baseada em Soclade: Re-enraizamento do Filograma e Extração de Variáveis Relacionadas ao Objetivo	44
Figura 11 – Lista Baseada em Scophenetic: Ordenação de Variáveis por Distância Cofenética ao Objetivo com Threshold Pré-definido	45
Figura 12 – Árvore Filogenética Gerada a partir de 54 Variáveis Heterogêneas da FABC	54
Figura 13 – Filograma C1B8C: Análise de Sensibilidade no Par p18 (C1B8C e C1W8C)	55
Figura 14 – Filograma C1W8C: Análise de Sensibilidade no Par p18 (C1B8C e C1W8C)	56
Figura 15 – Filograma C2B8C: Análise de Sensibilidade no Par p28 (C2B8C e C2W8C)	56
Figura 16 – Filograma C2W8C: Análise de Sensibilidade no Par p28 (C2B8C e C2W8C)	57
Figura 17 – Filograma C1B4C: Descendência de β no Melhor Desempenho (Par q14)	59
Figura 18 – Filograma C1W4C: Descendência de β no Pior Desempenho (Par q14)	59
Figura 19 – Filograma Re-enraizado em ProdutividadeRealizadakgha: Variáveis Próximas ao Nó Enraizado	60
Figura 20 – Árvore Filogenética do rVP: Variáveis Mais Relevantes para o Modelo Final	62
Figura 21 – Memberships em Árvore Filogenética para Dados <i>Weak</i>	65
Figura 22 – Memberships em Árvore Filogenética para Dados <i>Medium</i>	65
Figura 23 – Memberships em Árvore Filogenética para Dados <i>Strong</i>	66
Figura 24 – Memberships em Árvore Filogenética para Dados da FABC	67
Figura 25 – Análise da CC dos Dados Weak: Evolução e Configurações Otimizadas em BBs	71
Figura 26 – Análise da CC dos Dados Medium: Evolução e Configurações Otimizadas em BBs	72

Figura 27 – Análise da CC dos Dados Strong: Evolução e Configurações Otimizadas em
BBs 73

Figura 28 – Análise da CC dos Dados da FABC: Evolução e Configurações Otimizadas
em BBs 74

Figura 29 – Teste de Assimetria e Curtose 97

LISTA DE TABELAS

Tabela 1 – Questões de pesquisa e suas descrições	26
Tabela 2 – Bases de Dados Utilizadas	26
Tabela 3 – Conteúdo do formulário de extração dos dados	28
Tabela 4 – Distribuição de probabilidades conjuntas para <i>Weak</i> , <i>Medium</i> e <i>Strong</i>	37
Tabela 5 – Modelo de Probabilidade Marginal para Quatro Variáveis	49
Tabela 6 – Congruência - Maior Número de Nós Folha Comuns por Categoria	55
Tabela 7 – Listas baseadas em clados (s2i, s4i, s8i, s16i, sclade)	57
Tabela 8 – Variáveis Seleccionadas pelo SM2 e Scriterion	58
Tabela 9 – Distâncias cophenéticas de ProdutividadeRealizadaakgha a Leaf (da menor para a maior)	61
Tabela 10 – $rVP = (Sclade \cup Scriterion) \cap (Soclade \cup Scophenetic)$	63
Tabela 11 – Variáveis por Membership	64
Tabela 12 – Resumo dos 5 melhores, 5 medianos e 5 últimos resultados dos dados <i>Weak</i>	67
Tabela 13 – Resumo dos 5 melhores, 5 medianos e 5 últimos resultados dos dados <i>Medium</i>	68
Tabela 14 – Resumo dos 5 melhores, 5 medianos e 5 últimos resultados dos dados <i>Strong</i>	68
Tabela 15 – Resumo dos 5 melhores, 5 medianos e 5 últimos resultados dos dados da FABC	70
Tabela 16 – Atividades de Pesquisa e Cronograma.	77
Tabela 17 – Estudos Primários Seleccionados para Revisão Sistemática	84
Tabela 18 – Descrição das variáveis da Fundação ABC	95

LISTA DE ABREVIATURAS E SIGLAS

BB	Building Block
C1BiC	Clado 1 Best, Categoria i (2, 4, 8, 16)
C2WiC	Clado 2 Worst, Categoria i (2, 4, 8, 16)
CC	Complexidade Combinada
CCC	Critério de Complexidade Combinada
CE	Critérios de Exclusão
CI	Critérios de Inclusão
CM	Complexidade do Modelo
CP	Complexidade da População Comprimida
DAMICORE	Data-Mining of Code Repositories
eCGA	Extended Compact Genetic Algorithm
EDA	Algoritmos de Estimação de Distribuição
FABC	Fundação ABC
FN	Fast Newman
Fs-OPA	Feature Sensitivity and Optimization Based on Phylogenetic Analysis
GA	Algoritmos Genéticos
MDL	Minimum Description Length
MPM	Modelo de Produto Marginal
NCD	Normalized Compression Distance
NJ	Neighbor Joining
RQs	Research Questions (em português, "questões de pesquisa")
rVP	Variáveis Principais
SM	Sampling from a Phylogram Model
SM1	Análise de Irmãos
SM2	Análise de Objetivo Específico
SM3	Análise de Clado de Objetivos
SM4	Análise de Distância Cofenética

SUMÁRIO

1	INTRODUÇÃO	17
2	REVISÃO DA LITERATURA	23
2.1	Mapeamento Sistemático da Literatura	24
2.1.1	Planejamento	25
2.1.2	Extração e síntese de dados	28
2.1.3	Resultados	28
2.2	Considerações Finais da Revisão	32
3	METODOLOGIA	33
3.1	Metodologia de Pesquisa	33
3.2	Etapas do Processo da Pesquisa	34
3.2.1	Planejamento	34
3.2.2	Execução	35
3.2.3	Validação	35
3.3	Conjuntos de Dados	35
3.3.1	Dados da Fundação ABC	35
3.3.2	Dados sintéticos	36
3.4	Descrição e Justificação da Metodologia Proposta	37
3.5	Geração e Análise de Filogramas com DAMICORE	38
3.5.1	Normalized Compression Distance (NCD)	38
3.5.2	Neighbor Joining (NJ)	39
3.5.3	Fast Newman (FN)	40
3.5.4	Construção de Filogramas com DAMICORE	41
3.5.5	Análise de Filogramas	42
3.5.5.1	Análise de Irmãos (SM1)	43
3.5.5.2	Análise de Objetivo Específico (SM2)	43
3.5.5.3	Análise de Clado de Objetivos (SM3)	44
3.5.5.4	Análise de Distância Cofenética (SM4)	44
3.5.6	Discretização de Variáveis	45
3.5.6.1	Discretização Univariada	46
3.5.6.2	Discretização Bivariada	46
3.5.6.3	Discretização Bivariada com o Algoritmo de Hartemink	47

3.6	Desenvolvimento do Modelo Probabilístico	47
3.6.1	<i>Fundamentos Probabilísticos do MPM</i>	48
3.6.2	<i>Formulação do Princípio MDL</i>	48
3.6.3	<i>Modelo de Probabilidade Conjunta e Entropia Conjunta</i>	49
3.6.4	<i>Definição do Critério de Complexidade Combinada (CCC)</i>	50
3.6.5	<i>Formulação do Problema de Otimização</i>	50
3.7	Partições do CCC e Memberships do DAMICORE	51
3.8	Conclusão do Capítulo	52
4	RESULTADOS PRELIMINARES	53
4.1	Análise dos Filogramas	54
4.1.1	<i>Árvore Filogenética: 54 Variáveis Heterogêneas</i>	54
4.1.2	<i>Análise dos Filogramas pelo Método SM1</i>	55
4.1.3	<i>Análise dos Filogramas pelo Método SM2</i>	58
4.1.4	<i>Análise do Filograma pelo Método SM3</i>	59
4.1.5	<i>Análise do Filograma pelo Método SM4</i>	60
4.2	Resultados do Modelo baseado no Phylograma	64
4.3	Resultados do Modelo baseado na Complexidade Combinada	66
5	CONCLUSÕES PRELIMINARES	75
6	CRONOGRAMA	77
6.1	Cronograma de Atividades	77
REFERÊNCIAS		79
APÊNDICE A	ESTUDOS PRIMÁRIOS SELECIONADOS	83
APÊNDICE B	PSEUDOCÓDIGOS	91
APÊNDICE C	NOMENCLATURA	95
APÊNDICE D	TESTE DE ASSIMETRIA E CURTOSE	97

INTRODUÇÃO

Justificativa e Relevância do Estudo

Em contextos dinâmicos, tomar decisões em ambientes complexos exige a integração e análise precisa de informações provenientes de múltiplas fontes e sistemas. Este estudo explora problemas do mundo real, utilizando dados heterogêneos de diversas origens – como informações geográficas, locacionais, agrometeorológicas, edáficas e genotípicas –, disponibilizados pela Fundação ABC. A variedade desses dados, combinada com a complexidade dos sistemas de informação modernos, gera desafios significativos que só podem ser superados por meio de abordagens inovadoras e robustas, capazes de formular decisões precisas e bem fundamentadas.

O avanço das tecnologias de aquisição de dados, impulsionado pela Internet das Coisas, expandiu a disponibilidade de informações espaciais provenientes de fontes diversas. Conforme destaca [Lopes \(2023\)](#), essa crescente oferta de dados heterogêneos multifontes – que abrange sensores, satélites, pluviômetros e bases de dados sociais – permite a criação de mapas coropléticos, facilitando a interpretação de fenômenos geográficos e populacionais. No entanto, integrar esses dados e avaliar suas distribuições espaciais apresenta desafios importantes, particularmente no que diz respeito à definição dos pesos de cada componente. Para enfrentar esse problema, o trabalho propõe um modelo espacial multicritério que otimiza tanto a dependência quanto a heterogeneidade espacial, atribuindo pesos adequados a cada variável e gerando mapas coropléticos automaticamente, sem necessidade de intervenção especializada. Estudos de caso validaram a eficácia dessa abordagem, permitindo comparar a qualidade das soluções com o custo computacional envolvido, além de contribuir para o desenvolvimento de novas técnicas de fusão e manipulação de dados geoespaciais.

Este estudo combina duas metodologias complementares para enfrentar esse problema. A primeira emprega técnicas avançadas de modelagem baseadas em análise filogenética, aplicando quatro métodos distintos para reduzir o conjunto de dados a um subconjunto compacto denomi-

nado *rVP*. Posteriormente, emprega-se um modelo fundamentado no Critério de Complexidade Combinada (CCC) para identificar a estrutura dos subproblemas, ou *building blocks* (BBs), e desenvolver modelos preditivos que integram esses BBs usando Algoritmos de Estimação de Distribuição (AED) ou modelos gráficos probabilísticos dirigidos, que permitem que os modelos sejam interpretáveis, explicáveis, potencialmente causais e transportáveis. A proposta busca construir um modelo estrutural robusto e confiável, capaz de estabelecer relações causais entre as variáveis analisadas. Essa robustez é crucial para lidar com a variabilidade de cenários reais, já que um experimento bem-sucedido em uma região específica do Brasil pode não ser replicável em outro local ou período. Isso reforça a necessidade de um modelo adaptável, que mantenha alto desempenho em diferentes contextos espaciais e temporais.

A primeira metodologia proposta utiliza técnicas avançadas de modelagem baseadas em análise filogenética, aplicando quatro métodos distintos (SM1, SM2, SM3 e SM4) para reduzir um conjunto de dados composto por 3.674 registros e 286 variáveis, fornecido pela Fundação ABC. O objetivo é extrair um subconjunto compacto, explicável e manejável para fins preditivos. O resultado dessa etapa, denominado *rVP*, consiste na união e interseção criteriosamente avaliadas dos modelos gerados pelos quatro métodos, marcando a primeira fase da análise. Esse resultado foi discutido com a equipe interdisciplinar da Fundação ABC para avaliar sua eficácia e propor refinamentos.

A segunda metodologia baseia-se no CCC e no Princípio do Comprimento Mínimo de Descrição (MDL). O CCC avalia a eficácia dos Modelos de Produto Marginal (MPMs) na formação de partições, identificando com precisão as dependências-chave entre as variáveis. Os MPMs utilizam o MDL para priorizar a simplicidade do modelo, permitindo maior complexidade apenas quando isso resulta em ganhos significativos de precisão. Nesse contexto, os MPMs organizam e exploram os blocos de construção, ou seja, subconjuntos de variáveis interdependentes, possibilitando a criação de partições que agrupem variáveis intimamente relacionadas. Ao minimizar o CCC, otimiza-se a busca e a recombinação desses BBs, garantindo que o modelo capture relações essenciais sem sobreajuste, crucial para soluções robustas e de alta qualidade.

A relevância deste estudo vai além do âmbito acadêmico, impactando diretamente setores estratégicos como agricultura, saúde, indústria e urbanismo. Ao oferecer uma base sólida para a tomada de decisão, o modelo proposto pode apoiar a implementação de políticas mais eficazes e a otimização de recursos. Assim, o trabalho promove a integração de dados e análises avançadas, impulsionando o desenvolvimento tecnológico e a inovação na criação de modelos mais eficientes que aprimoram a inferência e a tomada de decisão em ambientes complexos.

Formulação do Problema

A análise de dados heterogêneos provenientes de múltiplas fontes apresenta desafios significativos devido à diversidade intrínseca desses dados. Neste estudo, partimos de um

conjunto inicial de 286 variáveis, o que amplifica a complexidade da análise e a necessidade de integrar diferentes tipos de dados, sejam eles espaciais ou temporais. Diante disso, surgem questões fundamentais:

Como reduzir um conjunto extenso de variáveis a um subconjunto compacto que preserve as características essenciais para análise preditiva e, ao mesmo tempo, identificar a estrutura subjacente do problema, permitindo a construção de modelos preditivos robustos, interpretáveis e adaptáveis a diferentes cenários espaciais e temporais?

Objetivos da Pesquisa

Objetivo Geral

Otimizar a identificação de padrões estruturais e associações entre variáveis em dados heterogêneos, visando melhorar a inferência e a tomada de decisão em cenários dinâmicos.

Objetivos Específicos

- Reduzir o conjunto de variáveis por meio da análise de filogramas, utilizando técnicas avançadas para identificar hierarquias sem depender de conhecimento prévio do domínio.
- Determinar as agrupações de variáveis geradas pelo modelo DAMICORE e pelo modelo probabilístico baseado no CCC, representando de forma eficiente as relações entre as variáveis.
- Comparar as agrupações formadas pelos modelos, identificando padrões consistentes e validando a robustez das abordagens de modelagem.

Hipóteses de Pesquisa

- O uso de técnicas avançadas de análise de filogramas permite reduzir o conjunto de variáveis a um subconjunto compacto (rVP), identificando sua hierarquia de forma eficiente sem depender de conhecimento prévio do domínio, resultando em um conjunto menor que reduz a complexidade, destacando um número mais relevante de variáveis.
- A aplicação do modelo DAMICORE e de um modelo probabilístico baseado no CCC possibilita identificar blocos de construção que representam interdependências estruturais entre variáveis. Esses blocos permitem uma representação eficiente das associações e revelam padrões estruturais relevantes para a modelagem.

- A comparação entre as agrupações geradas pelo modelo DAMICORE e pelo modelo probabilístico baseado no CCC evidencia convergências e divergências significativas, validando a consistência das relações identificadas e permitindo a construção de modelos estruturais robustos e adaptáveis.
- A utilização do conjunto de dados fornecido pela Fundação ABC permitirá avaliar o impacto dos modelos estruturais na produtividade agrícola, validando a eficácia dos métodos investigados. A integração dos blocos de construção por meio de Algoritmos de Estimação de Distribuição ou modelos gráficos probabilísticos dirigidos possibilitará a construção de modelos preditivos interpretáveis, explicáveis, potencialmente causais e transportáveis. Esses modelos serão adaptáveis e robustos, capazes de generalizar padrões identificados em diferentes cenários espaciais e temporais, contribuindo para a tomada de decisão em contextos dinâmicos.

Escopo de Trabalho

Este estudo propõe desenvolver uma metodologia para analisar dados heterogêneos fornecidos pela Fundação ABC. O foco é reduzir um conjunto inicial de 286 variáveis a um subconjunto compacto (rVP) por meio de análise filogenética. Além disso, será aplicado o CCC baseado no Princípio MPM e no MDL para identificar blocos de construção (*building blocks*) e criar modelos preditivos causais, interpretáveis e transportáveis.

O escopo deste estudo inclui:

- A integração de dados heterogêneos em um único marco analítico.
- A redução dimensional por meio de análise filogenética.
- A identificação de relações entre variáveis que formam blocos de construção utilizando os modelos probabilísticos DAMICORE e CCC.
- A validação dos modelos baseados no DAMICORE e CCC.

A metodologia desenvolvida é aplicável a contextos variados que lidam com dados complexos e variados, como saúde, indústria e agricultura, e busca oferecer uma base sólida para a tomada de decisões informadas em ambientes de alta complexidade.

Principais Contribuições

A principal contribuição deste trabalho é o desenvolvimento e validação de uma metodologia inovadora para análise de dados heterogêneos, que combina técnicas avançadas como análise filogenética, discretização de dados, CCC, MPM e MDL. Essa abordagem resulta em

uma ferramenta robusta capaz de identificar relações estruturais entre variáveis e otimizar a produtividade em contextos agrícolas. Além disso, a metodologia demonstra alta versatilidade, podendo ser adaptada para outros domínios que lidam com dados complexos, proporcionando insights valiosos para diversas áreas de análise de dados.

Organização do Trabalho

Este trabalho está organizado em cinco capítulos, cada um abordando aspectos distintos da pesquisa. O primeiro capítulo apresenta a justificativa, relevância, objetivos e escopo do estudo, estabelecendo o contexto para a análise de dados heterogêneos. O segundo capítulo traz a revisão da literatura, discutindo os conceitos teóricos fundamentais, como análise filogenética e o CCC . O terceiro capítulo descreve a metodologia proposta, detalhando o framework que integra diversas técnicas analíticas. O quarto capítulo expõe os resultados obtidos e discute a eficácia do framework com base em estudos de caso comparativos. Por fim, o quinto capítulo conclui o estudo, destacando as principais contribuições, as limitações da pesquisa e propondo direções para trabalhos futuros.

REVISÃO DA LITERATURA

Este capítulo apresenta um mapeamento sistemático que identifica o estado da arte no uso do CCC com ênfase nos modelos probabilísticos conhecidos como *Marginal Product Models* (MPMs). O MPM organiza e explora os BBs, capturando as dependências entre variáveis e constituindo o núcleo do algoritmo, enquanto o CCC ajusta essa estrutura para otimizar o desempenho do modelo.

[Holland \(1992\)](#) denominou *Building Blocks* os conjuntos de características bem adaptadas que formam subcomponentes essenciais em soluções eficazes. A capacidade dos algoritmos genéticos de identificar e recombinar estrategicamente esses blocos garante o alto desempenho das soluções.

Seguindo essa linha, [Goldberg \(2002\)](#) definiu elementos essenciais para desenvolver algoritmos genéticos (GAs) eficazes na resolução de problemas complexos. A gestão estruturada dos BBs é crucial para gerar soluções de alta qualidade, pois esses blocos representam subconjuntos de variáveis com alta probabilidade de compor soluções robustas. Ao focar na combinação e no crescimento desses BBs, os algoritmos podem obter soluções de forma mais eficiente do que os GAs convencionais.

A tomada de decisão baseada em dados heterogêneos exige uma estruturação adequada para representar fenômenos de forma explicável e confiável. Em problemas espaciais e temporais, a complexidade do processamento e da extração de informações aumenta, tornando essencial o uso de modelos estruturais e causais. Segundo ([LOPES et al., 2022](#)), a representação eficaz de dados provenientes de múltiplas fontes e a aplicação de análise multicritério são fundamentais para otimizar a gestão da informação e facilitar a interpretação dos resultados. Na Inteligência Artificial, modelos probabilísticos, como os AED, precisam garantir estabilidade e confiabilidade ao longo do tempo e em diferentes cenários. No entanto, a robustez desses modelos nem sempre se mantém quando aplicados a novos contextos. Para superar esse desafio, a identificação de BBs a partir de métricas apropriadas permite associar variáveis de forma eficiente, beneficiando

processos de otimização e tomada de decisão. A extração de padrões úteis para otimização multiobjetivo e análise baseada em múltiplos critérios favorece a construção de modelos mais interpretáveis e adaptáveis, permitindo inferências mais confiáveis.

Nesse contexto, diversas abordagens de *linkage learning* foram desenvolvidas para capturar dependências entre variáveis em problemas de otimização. Métodos que combinam *fitness-based linkage learning* e modelos condicionais demonstraram melhorias no desempenho em problemas com dependências sobrepostas (ANDREADIS; ALDERLIESTEN; BOSMAN, 2024). Além disso, técnicas de aprendizado de linkage em grafos foram aplicadas na clusterização espectral multi-visão para aprimorar a classificação de dados em cenários dinâmicos (WANG; JING, 2024). Também foram propostas abordagens que distinguem dependências direcionais e simétricas, aumentando a eficácia dos algoritmos genéticos (PRZEWOZNICZEK; FREJ; KOMARNICKI, 2024). No entanto, neste estudo, optamos por um modelo baseado no CCC, que utiliza o MPM e o princípio de MDL para capturar estruturas de dependência de forma otimizada, reduzindo a complexidade combinada e favorecendo a interpretabilidade e estabilidade do modelo.

Dessa forma, a escolha pelos termos “*Extended Compact Genetic Algorithm*” e “*Combined Complexity Criterion*” se justifica pela sua relevância na literatura e pela capacidade de capturar de forma eficiente as dependências entre variáveis. O eCGA emprega o CCC para avaliar e otimizar modelos probabilísticos, sendo o MPM um componente central desse processo. Esses conceitos enfatizam a análise estrutural dos BBs e a modelagem das dependências entre variáveis, estabelecendo uma base sólida para a revisão sistemática e integrando avanços teóricos e práticos dos algoritmos evolutivos.

2.1 Mapeamento Sistemático da Literatura

Recentemente, a aplicação do CCC, com foco no MPM e fundamentada no princípio MDL, demonstrou ser uma abordagem promissora para identificar e construir BBs, essenciais para otimizar modelos com alta precisão. O eCGA utiliza modelagem probabilística e penalizações baseadas na CC para identificar relações interdependentes entre variáveis, resolvendo de maneira eficiente o problema de *linkage learning*, que antes era um desafio significativo em algoritmos genéticos convencionais. Estudos apontam que modelos probabilísticos com baixa complexidade e alta compressão permitem ao eCGA construir particionamentos robustos, reduzindo redundâncias e promovendo maior precisão na análise de dependências entre variáveis. Essa abordagem amplia o potencial do CCC para tratar problemas de alta dimensionalidade e otimização evolutiva, consolidando sua relevância em diversos contextos de aplicação (DUQUE; GOLDBERG; SASTRY, 2008; HARIK, 1999).

Para conduzir este estudo, adotamos um método empírico por meio de um **estudo de mapeamento sistemático**, seguindo as diretrizes propostas por Petersen, Vakkalanka e Kuzniarz

(2015) e Kitchenham, Charters *et al.* (2007). Essa abordagem foi motivada pela necessidade de explorar o uso do CCC no contexto do MDL, com foco em sua aplicação para aprimorar a identificação e agrupamento de variáveis interdependentes (*linkage learning*) em modelos evolutivos.

O mapeamento sistemático organiza-se em três fases: Planejamento, Condução e Sumarização, as quais serão detalhadas a seguir.

1. **Planejamento:** Esta fase inicial engloba as atividades preparatórias essenciais para garantir a robustez do estudo. Ela inclui a definição clara dos objetivos de pesquisa, o estabelecimento das questões de pesquisa (RQs), a formulação de critérios de inclusão e exclusão, a seleção das fontes de estudo, a construção da *string* de busca e o detalhamento dos procedimentos metodológicos. O protocolo de revisão é formalizado nesta etapa, servindo como guia estruturado para todas as fases subsequentes.
2. **Condução:** Nesta fase, são realizadas as atividades práticas de busca, seleção e avaliação dos estudos. Os dados são coletados de acordo com os critérios previamente estabelecidos, eliminando duplicatas e trabalhos irrelevantes. A extração dos dados é feita de forma sistemática, utilizando formulários padronizados para garantir consistência e completude na coleta das informações relevantes.
3. **Sumarização:** A fase final consiste na análise, síntese e apresentação dos resultados consolidados. Os dados extraídos são organizados e interpretados para responder às questões de pesquisa, destacando padrões, tendências e lacunas na literatura. Documentamos as conclusões de forma clara, assegurando sua utilidade para pesquisadores e demais interessados.

Essa estrutura garante um processo transparente, replicável e rigoroso, alinhado às melhores práticas de revisão sistemática.

2.1.1 Planejamento

Nesta fase, define-se o protocolo de revisão, que inclui: (i) a definição das questões de pesquisa; (ii) a formulação da estratégia de busca; (iii) o estabelecimento dos critérios de inclusão e exclusão; e (iv) a descrição do processo de extração dos dados e da metodologia para sua síntese.

O principal objetivo deste mapeamento sistemático de estudo é identificar os trabalhos mais recentes sobre soluções eCGA com CC, investigando áreas de aplicação, metodologias predominantes e tendências no uso do CCC. Para tanto, foram definidas as seguintes RQs:

Estratégia e processo de busca

Para recuperar os estudos, realizamos um processo de seleção baseado em: (i) definição dos termos e construção da *string* de busca; (ii) seleção das fontes de pesquisa; (iii)

Tabela 1 – Questões de pesquisa e suas descrições

Questão de Pesquisa	Descrição
RQ1: Quais áreas de aplicação têm sido mais exploradas no uso do eCGA com complexidade combinada?	Identificar os principais domínios onde o CCC tem sido aplicado no contexto do eCGA.
RQ2: Quais metodologias e técnicas predominam na implementação do eCGA com complexidade combinada?	Compreender os métodos predominantes na integração do CCC em eCGA.
RQ3: Quais tendências, limitações e oportunidades futuras são identificadas na pesquisa sobre o uso do CCC no eCGA?	Destacar os desafios de pesquisa e apontar áreas potenciais para investigações futuras.

Fonte: Elaborada pelo autor.

estabelecimento dos critérios de inclusão e exclusão; e (iv) armazenamento dos dados.

String de Busca: Construímos a *string* de busca utilizando as palavras-chave em inglês: “*Combined Complexity Criterion*” OR “*Extended Compact Genetic Algorithm*”.

Selecionamos as bases de dados conforme os critérios discutidos por Dieste e Padua (2007). As bases utilizadas foram: ACM Digital Library, IEEE Xplore, Science Direct e Scopus (Tabela 2).

Tabela 2 – Bases de Dados Utilizadas

Base de Dados	Endereço Eletrônico
ACM Digital Library	< http://dl.acm.org >
IEEE Xplore	< http://ieeexplore.ieee.org >
Scopus	< http://www.scopus.com >

Fonte: Elaborada pelo autor.

Critérios de inclusão e exclusão

Para selecionar os estudos a serem analisados, aplicamos os seguintes critérios de inclusão e exclusão. Os critérios de inclusão foram: (CI1) artigos completos, revisados por pares ou capítulos de livros científicos; (CI2) documentos escritos em inglês; (CI3) publicações entre 2004 e 2024; (CI4) estudos disponíveis em bases indexadas; e (CI5) pesquisas diretamente relacionadas ao eCGA e ao CCC. Os critérios de exclusão foram: (CE1) estudos com acesso restrito ou sem texto completo; (CE2) trabalhos com relevância marginal ao tema; (CE3) publicações duplicadas entre bases de dados (sendo considerado o estudo mais completo); (CE4) documentos do tipo editoriais, resumos ou opiniões; e (CE5) estudos superados por pesquisas mais recentes.

Processo de Busca e Seleção dos Estudos Primários


Aplicamos a string de busca definida na Tabela 2 nas bases de dados, utilizando seus mecanismos avançados de pesquisa. Inicialmente, obtivemos 97 estudos, distribuídos da seguinte forma: Scopus (58), ACM Digital Library (21) e IEEE Xplore (18). Em seguida, utilizamos a ferramenta **Parsifal** ([PARSIFAL, 2020](#)) para organizar as referências, remover 38 duplicatas e extrair os dados necessários, resultando em 59 estudos únicos.

A seleção dos trabalhos relevantes para o mapeamento sistemático foi realizada em três fases, aplicando-se sucessivamente os critérios de inclusão e exclusão definidos anteriormente em trechos específicos dos documentos retornados pela busca inicial. Esse processo permitiu eliminar os estudos que não se alinhavam com o objetivo da revisão:

- a. **Fase I: Leitura de títulos e resumos.** Aplicamos os critérios de inclusão e exclusão a todos os trabalhos candidatos obtidos na busca inicial.
- b. **Fase II: Leitura das seções de introdução e conclusão.** Realizamos a leitura das seções de introdução e conclusão dos estudos selecionados na Fase I.
- c. **Fase III: Leitura completa dos trabalhos.** Analisamos integralmente os estudos remanescentes, considerando todo o seu conteúdo. Ao final desta fase, obtivemos a relação final dos textos incluídos na revisão.

A Figura 1 ilustra o processo de seleção dos estudos, evidenciando a aplicação dos critérios de inclusão e exclusão em cada fase.

Figura 1 – Distribuição dos estudos primários (fase de condução)



Fonte: Elaborada pelo autor.

Fase III: Leitura Completa dos Trabalhos

Na etapa final, os 21 estudos restantes foram analisados integralmente. Utilizou-se um formulário de extração pré-definido para coletar dados relevantes, como métodos, contribuições e resultados. Após essa revisão, todos os 21 estudos foram considerados relevantes e incluídos na análise detalhada do mapeamento sistemático.

2.1.2 Extração e síntese de dados

Para extrair e sintetizar os dados dos estudos selecionados, utilizamos um formulário estruturado que permitiu responder às questões de pesquisa e coletar informações adicionais, conforme ilustrado na Tabela 3. A pesquisa foi realizada entre novembro e dezembro de 2024, e os dados extraídos foram devidamente documentados, estando disponíveis em <https://bit.ly/4eCGA>.

Tabela 3 – Conteúdo do formulário de extração dos dados

Atributos	Conteúdo
ID	Identificação única do estudo.
Título do Estudo	Título completo do trabalho analisado.
Autores	Lista de autores responsáveis pelo estudo.
Ano	Ano de publicação do estudo.
Fonte	Base de dados ou periódico onde o estudo foi publicado.
Objetivo do Estudo	Finalidade central do trabalho, incluindo como o CCC foi aplicado no eCGA.
Metodologia	Métodos empregados, como estratégias de linking learning, formação de BBs e aplicação em problemas reais.
Resultados Principais	Principais descobertas, incluindo impactos na otimização e relevância prática.
Áreas de Aplicação	Domínios de aplicação, como sistemas complexos e dados heterogêneos.
Limitações	Restrições ou desafios identificados no estudo, como escalabilidade ou dependências de ordem superior.

Fonte: Elaborada pelo autor.


2.1.3 Resultados

Esta seção apresenta uma visão geral dos 21 estudos primários selecionados para o mapeamento sistemático. A Figura 2 ilustra a distribuição desses estudos de acordo com as bases de dados utilizadas. Observa-se que os estudos foram extraídos das seguintes fontes:

- **ACM Digital Library:** 6 estudos (28,6%);
- **IEEE Xplore:** 9 estudos (42,9%);
- **Scopus:** 6 estudos (28,6%).

Essa distribuição reflete a representatividade das bases de dados na seleção final dos trabalhos analisados. Os detalhes dos Estudos Primários Seleccionados para Revisão Sistemática estão no Apêndice A.

Figura 2 – Distribuição de Estudos por Base de Dados



Fonte: Elaborada pelo autor.

Esta seção apresenta uma visão geral dos 21 estudos primários seleccionados para o mapeamento sistemático. Para caracterizar os títulos e resumos dos estudos, foi gerada uma nuvem de palavras que ilustra os atributos de indexação mais comuns. Na Figura 3, o tamanho de cada termo reflete sua frequência de uso nos títulos e resumos das publicações analisadas. Observa-se que os termos mais frequentes incluem "*Genetic Algorithm*", "*Model*", "*ECGA*", "*Linkage Learning*", "*Probabilistic Method*", "*EDA*", "*Complex*", "*BB*" e "*EA*", entre outros.

Discussão das Questões de Pesquisa

As principais descobertas mostram que o CCC, fundamentado no princípio da MDL, desempenha um papel essencial na identificação de BBs por meio do aprendizado de ligação (*linkage learning*). Esse processo otimiza a formação de BBs, preservando relações críticas entre variáveis interdependentes, o que é fundamental para a eficiência dos algoritmos evolutivos. Essa abordagem se destaca em cenários complexos, envolvendo dados heterogêneos e alta dimensionalidade, onde a precisão e a robustez são cruciais. Na sequência, exploramos as principais áreas de aplicação, as metodologias mais utilizadas e as tendências promissoras relacionadas ao uso do CCC no eCGA.

A seguir, exploram-se os principais resultados obtidos em cada uma dessas categorias, destacando como o uso do CCC no eCGA contribui para avanços na solução de problemas complexos, na adoção de metodologias inovadoras e na identificação de caminhos promissores para futuras pesquisas.

otimizações mais precisas e eficientes (HARIK; LOBO; SASTRY, 2006; LIMA *et al.*, 2005; BRANCO *et al.*, 2011; MUNETOMO; SATAKE; AKAMA, 2007; CHUANG; HSU, 2010). Essa técnica garante que os "blocos de construção" sejam protegidos durante a recombinação, essencial para problemas complexos.

Além disso, o Princípio MDL e CCC orientam a escolha de modelos eficazes. O MDL favorece soluções simples e eficientes, enquanto o CCC combina a complexidade do modelo com a compressão populacional para avaliar a qualidade das soluções propostas (CHUANG; CHEN, 2010; BRANCO *et al.*, 2011; ICĂLNZAN; DUMITRESCU; HIRSBRUNNER, 2009; LANZI *et al.*, 2008; VERMA *et al.*, 2010). Para minimizar o CCC, algoritmos *greedy* são frequentemente utilizados, embora possam demandar maior custo computacional em problemas de larga escala (ICĂLNZAN; DUMITRESCU; HIRSBRUNNER, 2009; CHEN; CHEN, 2010).

Tendências, Limitações e Oportunidades Futuras

A escalabilidade continua sendo um desafio significativo no eCGA com CCC. Embora eficiente em problemas decomponíveis, sua aplicação a cenários de grande escala e alta complexidade estrutural requer melhorias contínuas (HARIK; LOBO; SASTRY, 2006; LANZI *et al.*, 2008; VERMA *et al.*, 2010; CHUANG; CHEN, 2010). Pesquisas futuras devem se concentrar em métodos que aprimorem sua capacidade de lidar com essas demandas, ampliando o alcance do algoritmo.

Outro aspecto promissor é o manejo de dependências de ordem superior. O eCGA tradicional foca em dependências de ordem inferior, mas avanços recentes indicam a necessidade de explorar interações mais complexas, potencialmente utilizando modelos baseados em clusters (LANZI *et al.*, 2008; LIMA *et al.*, 2005; HARIK; LOBO; SASTRY, 2006; ICLANZAN, 2012). Essa abordagem pode ampliar significativamente as aplicações do eCGA em problemas mais sofisticados.

No campo da otimização contínua, métodos de discretização adaptativa estão sendo desenvolvidos para melhorar o desempenho do eCGA em variáveis contínuas (CHEN; LIU; CHEN, 2006; CHEN; CHEN, 2010). Em paralelo, estratégias para manutenção da diversidade populacional, como reinício de populações e *niching*, são cruciais para otimização em ambientes dinâmicos (CHUANG; CHEN, 2010; LIMA; FERNANDES; LOBO, 2008; CHUANG; SMITH, 2013).

Por fim, a hibridização com buscas locais e a paralelização do processo de otimização têm reduzido custos computacionais e acelerado o tempo de execução (SASTRY; GOLDBERG; JOHNSON, 2007; LIMA *et al.*, 2005; MUNETOMO; SATAKE; AKAMA, 2007; ICĂLNZAN; DUMITRESCU; HIRSBRUNNER, 2009). Adicionalmente, a incorporação de informações prévias sobre a estrutura dos problemas pode melhorar ainda mais o aprendizado de ligação, aumentando a eficiência e eficácia do eCGA (ICĂLNZAN; DUMITRESCU; HIRSBRUNNER, 2009).

2.2 Considerações Finais da Revisão

Este mapeamento sistemático explorou o papel do CCC, fundamentado no Princípio da MDL e MPM, no contexto do eCGA. A análise demonstrou que o CCC identifica, por meio do aprendizado de ligação, os BBs que preservam as interações essenciais entre variáveis. Essa abordagem mostra grande potencial para problemas complexos, especialmente aqueles com alta dimensionalidade, heterogeneidade e dependências estruturais.

Os resultados evidenciam que o eCGA com CCC se destaca em cenários onde a decomposição de subestruturas é vital para alcançar soluções ótimas ou quase ótimas. Suas aplicações práticas abrangem desde a otimização de sistemas florestais e agrícolas até a detecção de comunidades em redes complexas e o monitoramento da qualidade de energia, reforçando seu valor em diversas áreas.

Principais Contribuições

- **Áreas de Aplicação:** O eCGA com CCC prova eficiência em problemas decomponíveis e funções enganosas, com aplicabilidade validada em cenários estocásticos e escaláveis.
- **Metodologia:** O aprendizado de ligação, suportado pelo MPM, mostra-se central na preservação das interações entre variáveis. A combinação de MDL com CCC permite selecionar modelos simples e eficientes.
- **Tendências e Limitações:** Embora eficaz para problemas de média escala, o eCGA enfrenta desafios em cenários de alta complexidade, especialmente na exploração de dependências de ordem superior e na adaptação a variáveis contínuas.

Na prática, o CCC fundamentado no Princípio da MDL e MPM oferece uma abordagem poderosa para otimizar processos em engenharia, ciência de dados e outras áreas que exigem soluções robustas. Teoricamente, a revisão consolida o entendimento do papel do CCC no aprendizado de ligação e destaca a importância de técnicas híbridas e paralelizadas para reduzir custos computacionais.

METODOLOGIA

Neste capítulo, serão descritas as diversas metodologias seguidas para alcançar os objetivos do estudo. A Seção 3.1 aborda a metodologia de pesquisa, detalhando a abordagem e natureza do estudo. A Seção 3.2 descreve as etapas do processo de pesquisa, destacando as fases de especificação, implementação e validação. Finalmente, a Seção 3.3 detalha o framework proposto para a análise de dados heterogêneos, focando na transportabilidade.

3.1 Metodologia de Pesquisa

A linha de pesquisa deste trabalho pertence ao tópico de análise de dados heterogêneos e inferência causal, que combina elementos das áreas de modelagem computacional e análise filogenética. Do ponto de vista da sua natureza, esta pesquisa é classificada como uma pesquisa aplicada. De acordo com [Gil \(2002\)](#), a pesquisa aplicada tem como objetivo gerar conhecimento para aplicação prática, contribuindo para a solução de problemas reais. Este estudo visa contribuir de forma prática na análise e inferência de dados heterogêneos para melhorar a precisão e eficiência na tomada de decisões, com um foco particular na transportabilidade dos modelos.

Do ponto de vista da abordagem do problema, a pesquisa é quantitativa. Para a pesquisa quantitativa, a preocupação é descrever com precisão as características dos dados, utilizando instrumentos padronizados para coleta e análise de dados, resultando em achados de natureza quantitativa. A análise quantitativa é essencial para extrair conhecimento, gerar modelos, simular dados e entender relações de forma quantificável.

Do ponto de vista dos objetivos do trabalho, a pesquisa é explicativa, pois pretende identificar os fatores que determinam a ocorrência dos fenômenos, em especial, as relações entre variáveis heterogêneas. A pesquisa busca explicar o comportamento das variáveis principais, identificando as razões e os porquês dos fenômenos observados.


Do ponto de vista dos procedimentos técnicos, a pesquisa é experimental, uma vez que

envolve a modelagem e validação de sistemas complexos. O processo experimental nos permite manipular variáveis, observar comportamentos e validar modelos inferenciais, garantindo a robustez e a transportabilidade dos modelos desenvolvidos.

3.2 Etapas do Processo da Pesquisa

O modelo proposto neste trabalho é dividido em três etapas principais: Especificação, Implementação e Validação, como ilustrado na Figura 4.

Figura 4 – Etapas do Processo da Pesquisa



Fonte: Elaborada pelo autor.

3.2.1 Planejamento

- **Dados:** Serão utilizados os dados reais da Fundação ABC, complementados por três conjuntos de dados sintéticos criados com diferentes níveis de força de probabilidade (*Weak*, *Medium* e *Strong*), que servirão de base para a etapa de modelagem probabilística.

- **Especificação e Definição do Problema:** Identificar claramente o objetivo do estudo, delimitando o domínio do problema, o alcance e a relevância da pesquisa.

- **Definição Teórica e Metodológica:** Definir o referencial teórico que fundamenta a análise, garantindo uma base sólida para o desenvolvimento do estudo. Selecionar métodos de análise e modelagem adequados, como o DAMICORE, a análise robusta de filogramas, a discretização bivariada e o Critério de Complexidade Combinada, assegurando a precisão e a relevância dos resultados.

3.2.2 Execução

Tratamento dos Dados Heterogêneos e Obtenção das Variáveis Principais (rVP): Selecionaremos e trataremos os dados disponíveis, gerando os filogramas por meio do DAMICORE. A partir de uma análise robusta desses filogramas, extrairemos as variáveis principais que orientarão o estudo.

Seleção dos Dados e Discretização: Selecionaremos os dados relevantes identificados no rVP e aplicaremos a discretização das variáveis contínuas. Utilizaremos a discretização bivariada, enfatizando o uso do algoritmo de Hartemink ([HARTEMINK, 2001](#)), que proporcionará uma divisão informada e ajustada às distribuições observadas, maximizando a retenção de informação.

Implementação do Modelo Probabilístico: Desenvolveremos um modelo probabilístico fundamentado no CCC e no MPM, integrando o princípio MDL. Esse modelo criará blocos de construção que servirão de base para o processo de otimização, utilizando AED ou modelos probabilísticos gráficos dirigidos. O modelo minimizará a complexidade combinada por meio do cálculo da probabilidade conjunta e da análise da entropia conjunta para ajustar as partições dos dados. Além disso, oferecerá uma visão quantitativa das relações entre as variáveis discretizadas.

3.2.3 Validação

Validaremos os resultados utilizando dados sintéticos e estudos de caso, comparando os modelos gerados pelo DAMICORE e pelo Critério de Complexidade Combinada. Nossa hipótese é que ambos os modelos produzirão memberships e partições semelhantes no contexto da formação dos *clusters* que constituem os *building blocks*. A análise dos memberships identificará agrupamentos significativos e verificará a consistência das associações entre os elementos do conjunto de dados. Simultaneamente, explorar a estrutura interna dos dados, com base nas partições do CCC, fornecerá insights sobre os *Building Blocks*, facilitando a compreensão das dependências entre as variáveis e aprimorando a eficiência da modelagem.

3.3 Conjuntos de Dados

3.3.1 Dados da Fundação ABC

A Fundação ABC é uma instituição privada e sem fins lucrativos que realiza pesquisas aplicadas para desenvolver soluções tecnológicas no agronegócio. Atende mais de 5 mil produtores rurais afiliados a diversas cooperativas e abrange uma área superior a 602 mil hectares, além de operar uma bacia leiteira de 868 milhões de litros por ano. A fundação também colabora com empresas e instituições de pesquisa, com sede, laboratórios e campos experimentais em Castro-PR ([FUNDACAOABC, 2025](#)).

Nesse contexto, este conjunto de dados referente à safra 2023/2024 da Fundação ABC,

contém 3.674 registros, abrangendo 286 variáveis distribuídas entre fatores agrometeorológicos, edáficos, de manejo e genotípicos. A análise concentra-se no subperíodo flor-colheita, permitindo investigar a produtividade da soja [kg/ha] em função das condições ambientais e práticas agrícolas.

As variáveis incluem localização geográfica dos talhões, altitude e propriedades do solo que afetam a retenção de água e nutrientes. No aspecto genotípico, são considerados os cultivares e seus respectivos propósitos. O manejo abrange datas de semeadura e colheita, além do uso de defensivos agrícolas, como fungicidas, herbicidas e inseticidas. Os dados agrometeorológicos englobam temperatura, radiação solar, umidade relativa e precipitação, além de índices derivados que indicam períodos críticos para o desenvolvimento da cultura.

Esses dados fornecem uma visão abrangente das condições em que a soja é cultivada, permitindo avaliar a influência de cada conjunto de variáveis no rendimento final. A análise de disponibilidade hídrica, incidência de doenças, fertilização e escolha de genótipos visa otimizar estratégias produtivas e promover a sustentabilidade agrícola. A riqueza e diversidade dos dados permitem estudos comparativos, modelagem preditiva e recomendações técnicas para aprimorar a tomada de decisões no manejo da cultura.

3.3.2 *Dados sintéticos*

A Tabela 4 apresenta a estrutura probabilística de três conjuntos de dados sintéticos gerados com diferentes configurações de força de associação entre variáveis.

- **Weak (0.1 - 0.2):** Este conjunto de dados possui distribuições probabilísticas mais uniformes, com valores balanceados em todas as combinações possíveis. É ideal para análises exploratórias, onde a influência entre variáveis é moderada ou fraca.
- **Medium (0.2 - 0.3):** Os dados apresentam uma concentração maior em algumas combinações específicas, indicando relações mais evidentes entre variáveis. Este conjunto é útil para testar modelos que procuram capturar padrões intermediários sem total dominância de algumas categorias.
- **Strong (0.1 - 0.4):** Caracteriza-se por uma forte concentração de probabilidades em poucas combinações dominantes, refletindo dependências bem definidas entre variáveis. Esse conjunto é adequado para avaliações de modelos em cenários altamente estruturados e com padrões claros.

Esses dados sintéticos foram projetados especificamente para apoiar a validação dos modelos probabilísticos, permitindo uma avaliação robusta da capacidade dos modelos em capturar padrões e associações presentes nas variáveis.

Tabela 4 – Distribuição de probabilidades conjuntas para *Weak*, *Medium* e *Strong*

Partição	<i>Weak</i> (0.1 - 0.2)	<i>Medium</i> (0.2 - 0.3)	<i>Strong</i> (0.1 - 0.4)
[1, 2, 5]	(0,0,0): 0.2 (0,1,1): 0.2 (1,0,2): 0.1 (1,1,0): 0.1 (0,0,1): 0.1 (1,1,2): 0.1 (0,1,0): 0.1 (1,0,1): 0.1	(0,0,0): 0.3 (0,1,1): 0.3 (1,0,2): 0.2 (1,1,0): 0.2	(0,0,0): 0.4 (0,1,1): 0.4 (1,0,2): 0.1 (1,1,0): 0.1
[4, 6, 9]	(0,0,0): 0.1 (0,1,1): 0.1 (1,0,2): 0.2 (1,1,3): 0.2 (0,1,0): 0.1 (1,0,1): 0.1 (1,1,2): 0.1 (0,0,3): 0.1	(0,0,0): 0.2 (0,1,1): 0.2 (1,0,2): 0.3 (1,1,3): 0.3	(0,0,0): 0.1 (0,1,1): 0.1 (1,0,2): 0.4 (1,1,3): 0.4
[3, 7, 8]	(0,0,0): 0.1 (1,1,1): 0.2 (2,0,0): 0.2 (0,1,1): 0.1 (1,0,1): 0.1 (2,1,0): 0.1 (0,1,0): 0.1 (2,1,1): 0.1	(0,0,0): 0.2 (1,1,1): 0.3 (2,0,0): 0.3 (0,1,1): 0.2	(0,0,0): 0.1 (1,1,1): 0.4 (2,0,0): 0.4 (0,1,1): 0.1

Fonte: Elaborada pelo autor.

3.4 Descrição e Justificação da Metodologia Proposta

A metodologia proposta neste estudo foi desenvolvida para enfrentar os desafios da análise de dados heterogêneos, como os da Fundação ABC, que incluem variáveis contínuas e discretas relacionadas a fatores agronômicos, climáticos e químicos. Esses dados apresentam alta complexidade, devido à sua natureza multidimensional e às dependências inter-relacionais, exigindo uma abordagem que combine robustez analítica com adaptabilidade.

Para garantir a eficácia da metodologia, foram utilizados dados sintéticos cuidadosamente projetados, simulando cenários com diferentes níveis de complexidade probabilística. Esses dados complementam os dados reais, permitindo uma validação rigorosa das técnicas empregadas. A combinação de DAMICORE, análise de filogramas, discretização bivariada e o Critério de Complexidade Combinada possibilita identificar padrões em variáveis heterogêneas, lidar eficientemente com a alta dimensionalidade e assegurar modelos precisos e parcimoniosos, alinhados aos objetivos do estudo.


3.5 Geração e Análise de Filogramas com DAMICORE

A geração de filogramas é uma etapa fundamental na metodologia proposta, pois possibilita a visualização de relações e padrões complexos em dados heterogêneos. Utilizando o DAMICORE, são aplicados três algoritmos principais que permitem representar essas relações de maneira clara e eficiente. Cada um dos algoritmos contribui de forma distinta para a análise dos dados, oferecendo diferentes perspectivas sobre as relações presentes.

A metodologia desenvolvida neste estudo baseia-se em uma sequência de três métodos bem definidos, implementados em Python 3.11. Uma das principais inovações deste enfoque é a capacidade de processar dados heterogêneos utilizando a **Distância por Compreensão Normalizada** (NCD, do inglês *Normalized Compression Distance*), uma métrica baseada na compressão para o cálculo de distâncias (LI *et al.*, 2004). Esse método permite que os dados de entrada sejam apresentados em diversos formatos e processados de forma eficaz, independentemente do formato original.

Conforme mostrado no diagrama de fluxo da Figura 5, os dados foram inicialmente processados através da NCD, gerando uma matriz de distâncias. A partir dessa matriz, foi construída uma árvore filogenética utilizando o método **Neighbor-Joining** (SAITOU; NEI, 1987). A árvore resultante (filograma) foi submetida a uma análise baseada no método do **Fast Algorithm** desenvolvido por Mark Newman, no qual foram avaliados aspectos como a proximidade entre os nós, os níveis hierárquicos dentro da árvore e os agrupamentos formados. Esses agrupamentos representam padrões de relações chave entre os elementos, facilitando a interpretação das conexões e similaridades dentro do conjunto em estudo, por meio da identificação de áreas de maior afinidade e estratégias de agrupamento consistentes.

Figura 5 – Fluxo das Etapas NCD, NJ e FN do DAMICORE



Fonte: Adaptado de (GASPAR-CUNHA *et al.*, 2022).

3.5.1 Normalized Compression Distance (NCD)

A primeira etapa da metodologia consiste na criação de uma matriz de distâncias utilizando a **NCD (Distância por Compreensão Normalizada, do inglês *Normalized Compression***

Distance), que mede a similaridade entre dois elementos com base na compressão dos dados. A NCD é calculada como:

$$NCD(a, b) = \frac{C(a \cup b) - \min(C(a), C(b))}{\max(C(a), C(b))} \quad (3.1)$$

onde $C(a)$ e $C(b)$ representam os tamanhos comprimidos dos elementos a e b , respectivamente, enquanto $C(a \cup b)$ é o tamanho comprimido da concatenação de ambos. O valor de $C(a \cup b)$ é o núcleo da métrica, pois representa o peso associado à combinação dos elementos a e b , refletindo o grau de associação entre eles. Esse valor normalizado, variando de 0 (elementos idênticos) a 1 (elementos completamente distintos), serve como a métrica base para o método e permite processar dados em sua forma original, independentemente do formato. Essa avaliação conjunta é fundamental para os próximos passos do DAMICORE, onde o peso derivado de $C(a \cup b)$ possibilita uma análise precisa das relações entre os elementos. Além disso, outras métricas, como a métrica vetorial, podem ser consideradas, especialmente para dados numéricos, expandindo a flexibilidade e aplicabilidade do método em contextos diversos de análise de dados.

3.5.2 Neighbor Joining (NJ)

A segunda etapa da metodologia consiste em converter a matriz de distâncias em uma rede, utilizando o algoritmo *Neighbor Joining* (NJ) para construir uma árvore filogenética. Este processo é realizado em três etapas principais:

1. **Seleção de Nós para a União:** Seleccionam-se dois nós da árvore-estrela atual, minimizando o somatório das comprimentos dos ramos. Essa seleção baseia-se na matriz M , calculada a partir da matriz de distâncias D pela fórmula:

$$M_{ij} = D_{ij} - \frac{(R_i + R_j)}{n - 2} \quad (3.2)$$

onde R_i é a divergência de rede para o nó i , definida como:

$$R_i = \sum_{j \neq i} D_{ij} \quad (3.3)$$

O par de nós com o menor valor em M é selecionado para a união.

2. **Cálculo das Comprimentos dos Ramos:** Após a seleção dos nós i e j , calculam-se as comprimentos dos ramos desses nós até o novo nó u na árvore, usando as seguintes equações:

$$S_{iu} = \frac{D_{ij}}{2} + \frac{(R_i - R_j)}{2(n - 2)} \quad (3.4)$$

$$S_{ju} = \frac{D_{ij}}{2} + \frac{(R_j - R_i)}{2(n - 2)} \quad (3.5)$$

3. **Atualização da Matriz de Distâncias:** Após a união dos nós, calcula-se uma nova matriz de distâncias D' de dimensão $(n-1) \times (n-1)$, na qual o novo nó u substitui os nós i e j . A atualização é realizada pela fórmula:

$$D'_{ku} = \frac{(D_{ik} + D_{jk})}{2} - \frac{D_{ij}}{2} \quad (3.6)$$

Este processo repete-se até que restem apenas dois nós na matriz, que são agrupados para formar o nó final na árvore filogenética (SAITOU; NEI, 1987).

Uma vez construídos os filogramas pelo **algoritmo Neighbor Joining (NJ)**, as relações hierárquicas entre os elementos podem ser analisadas e ajustadas conforme as necessidades específicas do estudo. O NJ gera árvores filogenéticas com base nas distâncias entre variáveis, identificando as relações mais próximas de forma eficiente. Sua capacidade de processamento rápido o torna particularmente adequado para grandes volumes de dados, proporcionando uma representação clara e estruturada das similaridades entre os elementos analisados.

3.5.3 Fast Newman (FN)

Dando continuidade aos métodos anteriores, o algoritmo **Fast Newman (FN)**, também conhecido como o *Fast Algorithm* de Mark Newman, é uma abordagem aglomerativa hierárquica projetada para maximizar a modularidade Q em cada etapa, formando uma estrutura hierárquica de clusters de maneira eficiente e escalável. Baseado na ideia de modularidade, o FN identifica comunidades ao combinar iterativamente os pares de comunidades que mais contribuem para o aumento de Q , medida que avalia a densidade das conexões internas em comparação com uma rede aleatória (NEWMAN, 2004). Essa técnica permite identificar grupos de elementos densamente conectados, facilitando o reconhecimento de padrões estruturais em redes grandes e complexas.

A mudança na modularidade ao unir duas comunidades u e v é dada pela seguinte fórmula:

$$\Delta Q_{uv} = 2(e_{uv} - a_u a_v), \quad (3.7)$$

onde:

- e_{uv} representa a fração de arestas que conectam diretamente as comunidades u e v ,
- a_u e a_v são as frações de arestas que conectam cada comunidade ao restante da rede.

Essa abordagem permite ao FN construir dendrogramas que representam a hierarquia das uniões, possibilitando o corte em diferentes níveis para obter o número desejado de comunidades. Essa flexibilidade torna o FN particularmente útil em DAMICORE para explorar e ajustar a

estrutura dos clusters conforme as características dos dados. Além disso, o FN é complementado por outros algoritmos de agrupamento, como *Edge Betweenness* e *Walktrap*, que podem ser escolhidos conforme as necessidades da análise, conferindo a DAMICORE a flexibilidade de adaptar-se a diferentes contextos e tamanhos de rede.


3.5.4 Construção de Filogramas com DAMICORE

Para aplicar o DAMICORE e destacar os registros, as variáveis e o objetivo da análise, foi necessário ajustar os dados, realizando o ranqueamento do objetivo, seguida de uma segmentação em partições estratégicas denominadas *Best* e *Worst*, definidas com base nos valores do objetivo. Esse processo permite identificar claramente os elementos de melhor e pior desempenho, facilitando uma análise direcionada e mais eficiente.

Como ilustrado na Figura 6, o diagrama de fluxo apresenta o processo de construção de categorias com base em objetivos, tanto em contextos mono-objetivo como multiobjetivo, com ênfase no caso mono-objetivo. Neste caso, os dados são ordenados em ranqueamento decrescente, onde as entradas são organizadas do maior para o menor valor. A partir dessa ordenação, aplica-se uma segmentação em percentis específicos — 50%, 25%, 12.5% e 6.25% — que servem como limites de corte para definir as partições de dados.

Esses percentis geram um total de 8 partições que diferenciam os melhores e piores resultados dentro de cada intervalo. A divisão em categorias fornece um ponto de referência sólido, permitindo a criação de subconjuntos de dados bem definidos para uma análise aprofundada e orientada pelo objetivo específico. Essa abordagem possibilita identificar padrões e insights críticos para a tomada de decisão baseada nos objetivos definidos.

Figura 6 – Fluxo para Construção de Categorias Baseadas no Ranqueamento do Objetivo




Fonte: Elaborada pelo autor.

Nesta etapa, o DAMICORE é aplicado para a geração de filogramas e o cálculo do *membership* de cada elemento em relação às diversas partições definidas. O objetivo central é construir filogramas que serão posteriormente analisados para identificar padrões de similaridade

e estruturas de agrupamento nos dados. Cada partição é processada individualmente, permitindo uma análise comparativa entre os conjuntos organizados de acordo com percentis específicos.

Para facilitar a interpretação das partições, adota-se a notação B e W para representar os subconjuntos *Best* e *Worst*, respectivamente. Assim, são definidos oito subconjuntos, indicados como B_iC e W_iC , onde i assume os valores 2, 4, 8 e 16, correspondendo aos percentis de 50%, 25%, 12.5% e 6.25%, respectivamente. A Figura 7 apresenta o diagrama de fluxo do uso do DAMICORE para cada partição, destacando as etapas de processamento e o fluxo para a geração dos filogramas.

Figura 7 – Fluxo do DAMICORE por Partição: Geração dos Filogramas



Fonte: Elaborada pelo autor.


3.5.5 Análise de Filogramas

A seguir, descrevemos os principais procedimentos para a análise de filogramas, fundamentados no conceito de *Sampling from a Phylogram Model* (SM). O SM amostra um modelo filogenético cuja estrutura fornece a base probabilística para identificar variáveis-chave e suas relações. Integrado ao Fs-OPA – análise de sensibilidade de características e otimização baseada em filogramas – esse método aprende o problema a partir de dados brutos, construindo um filograma e gerando um modelo probabilístico aproximado, no qual os fatores são representados pelos nós-folha (KHARRAT *et al.*, 2020; KHARRAT; DELBEM, 2019). Esses procedimentos identificam as variáveis mais relevantes em diferentes cenários de desempenho, orientando a análise das interações entre variáveis e objetivos e garantindo uma abordagem eficiente e informada (KHARRAT *et al.*, 2020).

3.5.5.1 Análise de Irmãos (SM1)

O SM1 divide cada filograma em dois clados (C1 e C2) removendo o ramo central do maior caminho topológico, isolando as relações estruturais entre os nós-folha (variáveis) em diferentes cenários de desempenho. Em seguida, o método forma pares **C1BiC**, **C1WiC**, **C2BiC** e **C2WiC** (com B=best e W=worst) para cada categoria (2C, 4C, 8C, 16C), com base nos nós-folha compartilhados. Se o par mais congruente for (C1BiC, C1WiC), atribui-se $p_{1i} = (C1BiC, C1WiC)$ e $p_{2i} = (C2BiC, C2WiC)$; caso contrário, $p_{1i} = (C1BiC, C2WiC)$ e $p_{2i} = (C2BiC, C1WiC)$. Supondo $p_{1i} = (C1BiC, C1WiC)$, o SM1 compara cada par (x, y) , com x em C1BiC e y em C1WiC, e seleciona os nós-folha cujas relações de irmandade divergem entre os modelos, armazenando-os em s_{1i} . Em seguida, aplica o mesmo procedimento a p_{2i} para gerar s_{2i} . Por fim, o SM1 reúne s_{1i} e s_{2i} de todas as categorias na lista final, denominada **Sclade** (KHARRAT *et al.*, 2020). As variáveis identificadas nessa análise distinguem amostras de melhor e pior desempenho, fornecendo fundamentação para a modelagem e a resolução de problemas, como ilustrado na Figura 8.

Figura 8 – Lista Baseada em Clados: p_{1i} (p_{2i}) representa os Clados do Best e Worst Model Superior (Inferior). $s_{1i} = \{A, B\}$ ($s_{2i} = \{\}$), Resultando em $sclade = \{A, B\}$




Fonte: Elaborada pelo autor.

3.5.5.2 Análise de Objetivo Específico (SM2)

O SM2 utiliza os mesmos quatro clados encontrados pelo SM1 (C1BiC, C2BiC, C1WiC, C2WiC) para cada categoria i . Além disso, define um par único, q_{1i} , composto pelos clados dos modelos de melhor e pior desempenho que contêm a feature-alvo. O algoritmo transforma o nó-alvo β em um nó-pai e extrai toda a sua descendência, identificando a menor subárvore que contenha β e seus descendentes nos filogramas de BC_i e WC_i . Em seguida, armazena esses nós em uma lista denominada **Scriterion**, que reflete as variáveis com relações significativas com β .

e as variações dessas relações entre os melhores e os piores resultados (KHARRAT *et al.*, 2020), conforme ilustrado na Figura 9.

Figura 9 – Listas Baseadas em Critérios: Subárvores destacadas em azul com Nó A como Alvo. scriterion = {A, B, C}




Fonte: Elaborada pelo autor.

3.5.5.3 Análise de Clado de Objetivos (SM3)

O SM3 utiliza o filograma do problema e o re-enraíza em um nó folha específico (por exemplo, "ProdutividadeRealizadakgha"). Em seguida, realiza uma travessia em ordem de nível para extrair as camadas do filograma, organizando os nós em listas conforme sua profundidade e formando um "oclade"(clado de objetivos), armazenado na lista **Soclade**, como mostrado na Figura 10. Esse procedimento identifica as variáveis intimamente relacionadas aos objetivos em termos filogenéticos e oferece uma visão estruturada dos padrões hierárquicos dos dados.

Figura 10 – Lista Baseada em Soclade: Re-enraizamento do Filograma e Extração de Variáveis Relacionadas ao Objetivo




Fonte: Elaborada pelo autor.

3.5.5.4 Análise de Distância Cofenética (SM4)

O SM4 ordena as variáveis cuja distância cofenética em relação a um objetivo (por exemplo, "ProdutividadeRealizadakgha") esteja abaixo de um threshold predefinido e as armazena

na lista **Scophenetic**. Para isso, calcula-se a matriz de distâncias do filograma e determina-se a distância entre a folha-alvo e as demais, organizando as variáveis em ordem crescente, como mostrado na Figura 11. Esse procedimento identifica variáveis fortemente associadas ao objetivo, contribuindo para uma modelagem robusta e análises direcionadas.

Figura 11 – Lista Baseada em Scophenetic: Ordenação de Variáveis por Distância Cofenética ao Objetivo com Threshold Pré-definido



Fonte: Elaborada pelo autor.

Finalmente, as listas geradas pelos procedimentos (**Sclade**, **Scriterion**, **Soclade**, **Scophenetic**) são combinadas de forma estratégica para formar um conjunto único de Variáveis Principais, denominado **rVP**. Essa combinação é realizada por meio da seguinte estratégia matemática:

$$rVP = (Sclade \cup Scriterion) \cap (Soclade \cup Scophenetic) \quad (3.8)$$

Essa integração identifica e destaca as variáveis mais relevantes, oferecendo uma visão abrangente que facilita a construção de modelos robustos. Como resultado, análises direcionadas tornam-se mais eficientes, melhorando a interpretação dos dados e auxiliando na tomada de decisões estratégicas baseadas em evidências. Os detalhes dos algoritmos podem ser encontrados no Apêndice B.

3.5.6 Discretização de Variáveis

Nos enfrentamos com um problema real e complexo, composto por dados heterogêneos de múltiplas fontes, totalizando 286 variáveis, o que dificulta a interpretabilidade do modelo. Para lidar com essa complexidade, adotamos a discretização, que atenua a sensibilidade a valores extremos, unifica escalas e reduz a quantidade de valores possíveis. Com isso, ampliamos a eficiência computacional e a clareza dos resultados. Em cenários com muitas variáveis e possíveis relações não lineares, essa abordagem agrega robustez à análise.

A discretização é uma técnica amplamente utilizada na análise de dados para converter variáveis contínuas em categorias discretas, facilitando a modelagem e a interpretação. Essa transformação reduz a dimensionalidade dos dados, simplifica a estrutura dos modelos e melhora

a eficiência computacional, especialmente em cenários com volumes limitados de dados ou quando os algoritmos requerem entradas categóricas. Existem diferentes abordagens para a discretização, dependendo de como as variáveis se relacionam entre si. Nesta seção, exploramos tanto a discretização univariada quanto a discretização bivariada, com um enfoque especial na preservação das dependências estatísticas entre variáveis.

3.5.6.1 Discretização Univariada

A discretização univariada transforma cada variável contínua de maneira independente, convertendo-a em uma variável categórica. O processo consiste em dividir o domínio de uma única variável em intervalos discretos, permitindo a aplicação de técnicas de modelagem baseadas em dados categóricos. Os métodos mais comuns incluem:

- **Discretização por intervalos:** divide o domínio contínuo da variável em subintervalos de tamanho igual, independentemente da distribuição dos dados.
- **Discretização por quantis:** garante que cada intervalo contenha aproximadamente o mesmo número de observações, levando em consideração a distribuição dos dados.

Embora a discretização univariada seja eficaz para simplificar a análise, ela não preserva as interações entre variáveis (LIU *et al.*, 2002). Isso pode resultar na perda de informações importantes em contextos onde as dependências entre variáveis são cruciais para a modelagem, como em redes bayesianas. Para resolver esse problema, utilizamos a discretização bivariada.

3.5.6.2 Discretização Bivariada

A discretização bivariada transforma simultaneamente dois conjuntos de dados contínuos em categorias discretas, preservando suas relações estatísticas. Para minimizar a perda de informação, a técnica mantém as dependências entre variáveis ao longo do processo (HARTENK, 2001). Essa abordagem preserva a estrutura estatística, melhora a representatividade dos dados e otimiza a eficiência computacional. Em modelos como redes bayesianas, a manutenção da informação mútua entre variáveis assegura maior precisão na modelagem das correlações, resultando em análises mais robustas sem comprometer a interpretabilidade.

Ao contrário da discretização univariada, a discretização bivariada visa maximizar a informação mútua entre as variáveis contínuas transformadas, preservando as características conjuntas das distribuições e suas relações. Isso garante que a transformação das variáveis contínuas em categorias discretas mantenha as dependências necessárias para que o modelo seja representativo e confiável.

3.5.6.3 Discretização Bivariada com o Algoritmo de Hartemink

O algoritmo de Hartemink é uma das abordagens mais eficazes para a discretização bivariada. Seu objetivo é maximizar a preservação da informação mútua entre os pares de variáveis contínuas ao transformá-las em categorias discretas. Essa técnica é amplamente utilizada em redes bayesianas e outros modelos probabilísticos que dependem da interdependência entre variáveis.

O funcionamento do algoritmo de Hartemink é descrito a seguir:

- Para cada par de variáveis contínuas x_1 e x_2 , o algoritmo identifica os pontos de corte que melhor preservam a dependência estatística entre elas.
- A informação mútua entre as variáveis x_1 e x_2 é calculada, com o objetivo de maximizar essa informação ao transformar os dados em categorias discretas.
- A discretização resultante garante que os padrões de correlação e interdependência entre x_1 e x_2 sejam mantidos, evitando a perda de informações importantes que poderia ocorrer com uma discretização univariada aplicada separadamente a cada variável.

A discretização bivariada desempenha um papel fundamental na construção de modelos probabilísticos precisos e robustos, especialmente em redes bayesianas. O algoritmo de Hartemink é uma das abordagens mais eficazes para esta tarefa, pois busca maximizar a preservação da informação mútua entre pares de variáveis contínuas, garantindo que a transformação em categorias discretas mantenha as interdependências estatísticas relevantes (HARTEMINK, 2001). Essa preservação é essencial para capturar de forma precisa as relações presentes nos dados originais, evitando a perda de informações cruciais que ocorreria com uma discretização univariada.

Ao transformar variáveis contínuas em categorias discretas preservando as dependências existentes, a discretização bivariada melhora significativamente a capacidade de inferência dos modelos probabilísticos e a qualidade das previsões. Além disso, essa abordagem simplifica a complexidade computacional sem comprometer a integridade das interações entre as variáveis, favorecendo a identificação de padrões subjacentes e possibilitando a geração de novos pontos de busca de maneira mais eficiente e orientada (HARTEMINK, 2001; PELIKAN; GOLDBERG; LOBO, 2002).

3.6 Desenvolvimento do Modelo Probabilístico

Os Algoritmos de Estimação de Distribuições, AEDs, são uma variação dos Algoritmos Genéticos, AGs, que não utilizam operadores de cruzamento e mutação. Em vez disso, os EDAs constroem um modelo probabilístico com base nas soluções mais promissoras encontradas até o momento, utilizando esse modelo para gerar novos indivíduos. A forma como os EDAs

representam as dependências entre variáveis impacta diretamente tanto a complexidade quanto o desempenho do algoritmo (SHAO; YU, 2013).

O *extended Compact Genetic Algorithm*, eCGA, é um dos EDAs mais relevantes, pois modela as dependências entre variáveis ao agrupá-las e assumir que cada grupo seja mutuamente independente. O eCGA utiliza o modelo, denominado Modelo de Produto Marginal, que representa a estrutura das variáveis por meio de partições, agrupando aquelas que apresentam dependências estatísticas, e atribui a cada grupo uma distribuição probabilística específica (HARIK, 1999).

O eCGA parte da premissa de que uma boa distribuição probabilística equivale ao aprendizado das relações entre variáveis (*linkage learning*). A qualidade dessa distribuição é determinada por dois critérios: a representação comprimida da população sob a distribuição escolhida e a representatividade da distribuição de acordo com a estrutura do problema (VERMA *et al.*, 2010; DUQUE; GOLDBERG; SASTRY, 2008; HARIK; LOBO; SASTRY, 2006). Esses critérios constituem o CCC, definido como a soma da Complexidade do Modelo (C_m) e da Complexidade da População Comprimida (C_p). Neste contexto, C_m mensura o custo de armazenamento da estrutura do MPM, enquanto C_p quantifica a perda de informação associada à compressão da população.

3.6.1 Fundamentos Probabilísticos do MPM

Os *Modelos de Produto Marginal* (MPMs) adotados no eCGA particionam as variáveis de decisão de modo a capturar eficientemente suas interdependências. Para avaliar a qualidade dessas distribuições, o ECGA utiliza o princípio da MDL, conforme proposto por Rissanen (1978). Segundo o MDL, em condições de igualdade, distribuições mais simples são preferíveis às complexas, pois minimizam a redundância e garantem uma representação mais eficiente dos dados, penalizando modelos imprecisos ou excessivamente elaborados. Dessa forma, o eCGA assegura que cada MPM mantenha um equilíbrio ótimo entre simplicidade e capacidade preditiva, aprimorando a representação estatística do problema (HARIK, 1999).

A Estrutura do MPM é uma partição das variáveis em grupos independentes: MPM = [1,2], [3], [4]. Cada subconjunto representa um grupo de variáveis que compartilham relações estatísticas. Ao identificar que esses 4 bits estão correlacionados, eles são representados por meio de um MPM (ver Tabela 5), o que reduz o espaço de armazenamento para um quarto do necessário. Mesmo com probabilidades suaves e cada sequência apresentando probabilidade positiva, a entropia permanece baixa, favorecendo a compressão eficiente da informação.

3.6.2 Formulação do Princípio MDL

O Princípio da Descrição de Comprimento Mínimo (MDL) seleciona a hipótese $h \in H$ que minimiza a soma dos comprimentos necessários para descrever o modelo e os dados.

Tabela 5 – Modelo de Probabilidade Marginal para Quatro Variáveis

[1,2]	[3]	[4]
00 : 0,5	0 : 0,5	0 : 0,6
01 : 0,0	1 : 0,5	1 : 0,4
10 : 0,0		
11 : 0,5		

Fonte: Adaptado de (HARIK, 1999).

Matematicamente, é expresso como:

$$h_{MDL} = \arg \min_{h \in H} [L(h) + L(D|h)], \quad (3.9)$$

onde:

- $L(h) = -\log_2 P(h)$: comprimento da descrição do modelo h , relacionado à sua probabilidade.
- $L(D|h) = -\log_2 P(D|h)$: comprimento necessário para descrever os dados D dado o modelo h , refletindo o ajuste do modelo aos dados.

O logaritmo na base 2 ($\log_2$) é utilizado para expressar os comprimentos em bits, garantindo que o modelo escolhido seja o mais simples e eficiente em termos de compressão dos dados e da estrutura do modelo.

3.6.3 Modelo de Probabilidade Conjunta e Entropia Conjunta

A modelagem probabilística simplificada assume que a probabilidade conjunta de um conjunto de variáveis $X_1, X_2, \dots, X_n$ pode ser expressa como o produto das probabilidades marginais dos blocos de construção, isto é,

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^{N_{BB}} P(BB_i), \quad (3.10)$$

onde $P(BB_i)$ representa a probabilidade de cada bloco e N_{BB} o número total de blocos. De modo similar, a entropia conjunta do sistema é dada por

$$H(X_1, X_2, \dots, X_n) = - \sum_{i=1}^m P_i \log_2 P_i, \quad (3.11)$$

com P_i representando a probabilidade de cada combinação de valores e m o número total de combinações. Essas expressões reduzem a complexidade do modelo ao focar nas interações mais relevantes entre as variáveis.

3.6.4 Definição do Critério de Complexidade Combinada (CCC)

No eCGA, a otimização visa minimizar a CCC, definida como:

$$CCC = C_m + C_p \quad (3.12)$$

Onde C_m mede o custo de representação do modelo, e C_p avalia a entropia da população após a discretização. Para determinar a melhor estrutura, o CCC realiza uma busca gulosa, seguindo os seguintes passos:

1. Assume-se inicialmente que todas as variáveis são independentes.
2. Iterativamente, mescla-se subconjuntos de variáveis que mais reduzem $C_m + C_p$.
3. O processo continua até que nenhuma nova fusão consiga reduzir a complexidade combinada.

3.6.5 Formulação do Problema de Otimização

A função de otimização, baseada no MPM e no MDL, busca minimizar a soma da Complexidade do Modelo (C_m) e da Complexidade da População Comprimida (C_p), definindo assim o CCC como:

$$\min(C_m + C_p),$$

onde C_m quantifica o custo de armazenamento da estrutura dos blocos de construção, calculado como:

$$C_m = \log_2(N_p + 1) \sum_{i=1}^{N_{bb}} \left(2^{bb_{i,t}} - 1 \right),$$

sendo N_p o tamanho da população, N_{bb} o número total de blocos de construção e $bb_{i,t}$ o número de bits do bloco i . Por sua vez, C_p mede a perda de informação na compressão da população, definida por:

$$C_p = \sum_{i=1}^{N_{bb}} \sum_{j=1}^{2^{bb_{i,t}}} N_{ij} \log_2 \left(\frac{N_p}{N_{ij}} \right),$$

onde N_{ij} é o número de cromossomos que compartilham a j -ésima combinação de bits no bloco i .

O MDL atua de forma análoga à minimização da entropia condicional, reduzindo a incerteza dos blocos ao minimizar a redundância dos dados. A restrição

$$2^{bb_{i,t}} \leq N_p \quad \forall i \in \{1, \dots, N_{bb}\}$$

garante que o número de combinações possíveis em cada bloco seja compatível com o tamanho da população, evitando complexidade combinatória excessiva. Assim, ao minimizar $C_m + C_p$, o CCC preserva as dependências críticas e reduz a dimensionalidade do problema, resultando em uma representação compacta e eficiente da população (GOLDBERG, 2000).

3.7 Partições do CCC e Memberships do DAMICORE

A comparação entre as partições geradas pelo CCC e os memberships derivados do DAMICORE é uma etapa crucial para validar a consistência dos resultados deste estudo. Ambas as técnicas são sólidas e complementares na análise de dados heterogêneos. O DAMICORE permite analisar o árvore filogenético de quatro maneiras distintas, com a intenção de capturar padrões e identificar ligações fortes entre variáveis sob diferentes cenários amostrais do dataset. Aplicamos um filtro da variável 'Produtividade [kg/ha]', dividindo os dados em percentis (50%, 25%, 12.5%, 6.25%), onde, por exemplo, o 6.25% faz referência aos melhores em relação à 'Produtividade [kg/ha]'. O CCC visa minimizar a complexidade do modelo e dos dados, enquanto o DAMICORE, em sua última etapa, gera os memberships na forma de grupos, utilizando técnicas de análise filogenética para identificar relações e dependências entre variáveis. Ambas as abordagens buscam representar os dados de forma eficiente e revelar as estruturas relevantes.

Os resultados obtidos com o CCC e o DAMICORE são comparados para avaliar se há convergência entre as partições geradas por ambas as técnicas, analisando as variáveis identificadas sob diferentes abordagens, e se esses padrões podem ser utilizados em medidas de informação. Essa comparação é realizada considerando que, embora as abordagens sejam distintas, a existência de uma associação entre as variáveis deveria resultar em resultados similares ou iguais. O objetivo é garantir que as partições geradas sejam robustas e que as variáveis agrupadas estejam relacionadas de maneira consistente, independentemente da metodologia empregada.

Para a comparação entre as partições do CCC e os memberships do DAMICORE, foram considerados os seguintes passos:

- **Visualização dos Resultados:** Os filogramas gerados pelo DAMICORE e as partições obtidas pelo CCC foram visualizados para identificar possíveis discrepâncias ou similaridades visuais, facilitando a compreensão das relações entre as variáveis.
- **Análise da Convergência dos Clusters:** Foi realizada uma análise quantitativa para determinar se os clusters identificados pelas duas abordagens apresentam uma alta taxa de sobreposição, indicando uma convergência na estrutura dos dados.

A importância do modelo de avaliação comparativa entre CCC e DAMICORE reside em sua capacidade de fornecer uma validação cruzada robusta das técnicas empregadas. Ao analisar as similaridades e discrepâncias entre as partições, é possível obter insights sobre a adequação e eficácia de cada abordagem para diferentes tipos de dados. Esta avaliação garante que os agrupamentos obtidos representem, de maneira precisa, as relações subjacentes, aumentando a confiança na qualidade dos resultados e proporcionando uma base sólida para futuras análises e aplicações em contextos variados, como a produtividade agrícola.

3.8 Conclusão do Capítulo

Neste capítulo, detalhou-se a metodologia proposta para a análise de dados heterogêneos, abrangendo desde a seleção e tratamento dos dados até a aplicação de técnicas avançadas de discretização e modelagem probabilística fundamentada no CCC e no DAMICORE. Essa abordagem rigorosa assegura inferências precisas e a robustez do framework, preparando o terreno para a apresentação e discussão dos resultados no próximo capítulo.

RESULTADOS PRELIMINARES

Os resultados preliminares deste estudo são organizados em duas análises principais. A primeira análise baseia-se no estudo dos filogramas por meio de quatro métodos (SM1, SM2, SM3 e SM4). Utilizamos um conjunto de dados com 3.674 registros e 286 variáveis. O objetivo foi reduzir o número de variáveis e obter o rVP , que representa a união dos modelos gerados pelos quatro métodos. Após essa etapa, os resultados foram discutidos com a equipe interdisciplinar da Fundação ABC.

Durante a análise inicial, identificamos diversas variáveis irrelevantes para explicar a produtividade da soja. Essas variáveis foram removidas por não contribuírem significativamente. Entre elas estão: EstacaoAgrometeorologicadistanciam, ProdutividadeRealizadaclasses, CultivoPrincipal2324, NDUR>40sum, NDUR>50sum, NDUR>60sum, entre outras. Essas variáveis são altamente correlacionadas e podem ser substituídas por métricas mais representativas e evitar redundâncias.

Além disso, identificamos lacunas importantes no conjunto rVP , como a ausência de variáveis-chave que poderiam enriquecer a análise como Genótipos, Época de semeadura e Precipitação.

Após a filtragem criteriosa realizada pela Fundação ABC, chegamos a um conjunto de dados com 54 variáveis, que serviu como um novo ponto de partida para as análises subsequentes.

A segunda análise baseia-se no critério da complexidade combinada, com o objetivo de identificar os blocos de construção (*building blocks*) que representam as interações mais relevantes entre as variáveis. Para essa análise, foram considerados quatro conjuntos de dados:


1. Três conjuntos de dados sintéticos, criados especificamente para representar nove variáveis agrupadas da seguinte forma: [1, 2, 5], [3, 7, 8] e [4, 6, 9]. Cada conjunto foi projetado com diferentes níveis de força de probabilidade: fraca (*weak*), média (*medium*) e forte (*strong*).
2. Um conjunto de dados baseado no problema em estudo, reduzido ao subconjunto rVP .

4.1 Análise dos Filogramas

4.1.1 Árvore Filogenética: 54 Variáveis Heterogêneas

A Figura 12 exibe a árvore filogenética gerada pelo NJ a partir de 54 variáveis heterogêneas da FABC. A construção destes filogramas é realizada de forma iterativa para análises dos modelos SM1 e SM2, sendo este filograma essencial para os métodos SM3 e SM4. os modelos permitem identificar o rVP , definido como $rVP = (SM1 \cup SM2) \cap (SM3 \cup SM4)$, assegurando uma integração robusta e consistente dos resultados.

Figura 12 – Árvore Filogenética Gerada a partir de 54 Variáveis Heterogêneas da FABC



Fonte: Elaborada pelo autor.

4.1.2 Análise dos Filogramas pelo Método SM1


A Tabela 6 apresenta a congruência por categoria e os pares de congruência identificados, fornecendo uma visão estruturada das relações entre os modelos analisados. As Figura 13 e Figura 14 exibem os filogramas correspondentes ao par mais congruente $p18$ (C1B8C, C1W8C), permitindo a análise comparativa entre essas categorias. Nessas figuras, as variáveis destacadas em vermelho indicam mudanças observadas ao longo da comparação, evidenciando diferenças sensíveis entre os modelos. Por outro lado, as variáveis em azul permaneceram constantes, sugerindo estabilidade dentro do conjunto analisado. Esse contraste fornece informações valiosas sobre os padrões de variação entre os modelos e sua relevância dentro da categoria 8C.

Tabela 6 – Congruência - Maior Número de Nós Folha Comuns por Categoria

Cat.	Maior Congruência	Nós Comuns	Par p1i	Par p2i
2C	(C1B2C, C1W2C)	29	(C1B2C, C1W2C)	(C2B2C, C2W2C)
4C	(C1B4C, C1W4C)	29	(C1B4C, C1W4C)	(C2B4C, C2W4C)
8C	(C1B8C, C1W8C)	26	(C1B8C, C1W8C)	(C2B8C, C2W8C)
16C	(C1B16C, C1W16C)	26	(C1B16C, C1W16C)	(C2B16C, C2W16C)

Fonte: Elaborada pelo autor.


Figura 13 – Filograma C1B8C: Análise de Sensibilidade no Par p18 (C1B8C e C1W8C)



Fonte: Elaborada pelo autor.

Nas Figuras 15 e 16, são exibidos os filogramas referentes ao par complementar $p28$ (C2B8C, C2W8C). Assim como no primeiro par, as variáveis em vermelho representam elementos sensíveis à comparação, enquanto as variáveis em azul indicam estabilidade dentro da estrutura. A análise dessas diferenças permite compreender a influência de determinadas


Figura 14 – Filograma C1W8C: Análise de Sensibilidade no Par p18 (C1B8C e C1W8C)



Fonte: Elaborada pelo autor.

variáveis dentro do contexto da modelagem, auxiliando na identificação de padrões relevantes e na construção de uma base consistente para análises futuras.


Figura 15 – Filograma C2B8C: Análise de Sensibilidade no Par p28 (C2B8C e C2W8C)



Fonte: Elaborada pelo autor.

A partir da comparação entre os pares, as variáveis sensíveis são armazenadas em listas e organizadas por categoria. Essa abordagem permite consolidar as informações em uma estrutura

Figura 16 – Filograma C2W8C: Análise de Sensibilidade no Par p28 (C2B8C e C2W8C)



Fonte: Elaborada pelo autor.

coerente, facilitando a interpretação dos resultados. A Tabela 7 sintetiza essas comparações, agrupando as variáveis identificadas em cada categoria. A união de todas as categorias gera o resultado final de SM1, consolidado na lista **Sclade**, que contém 41 variáveis de interesse, representando o conjunto mais relevante para a análise do problema em questão.

Tabela 7 – Listas baseadas em clados (s2i, s4i, s8i, s16i, sclade)

Cat.	Nº	Elementos
s2i	16	3, 4, 5, 12, 16, 17, 20, 22, 25, 26, 27, 31, 34, 35, 38, 40
s4i	24	1, 3, 4, 5, 6, 7, 9, 12, 13, 16, 19, 20, 22, 25, 27, 28, 29, 30, 33, 34, 35, 36, 37, 40
s8i	30	1, 3, 4, 5, 6, 7, 9, 12, 16, 17, 18, 19, 20, 21, 22, 24, 25, 26, 27, 28, 30, 31, 32, 33, 34, 35, 36, 37, 40, 41
s16i	35	1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 22, 23, 24, 27, 28, 29, 30, 31, 33, 34, 35, 37, 38, 39, 41
Sclade	41	1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32, 33, 34, 35, 36, 37, 38, 39, 40, 41

Fonte: Elaborada pelo autor.

Codificação: 1: NHRAD > 1000 [sum]; 2: Tipo Safr; 3: NDPREC > 02 [sum]; 4: Altitude Mínima [m]; 5: Herbicida Planejado [aplicações]; 6: Colheita Data; 7: NDRAD > 20 [sum]; 8: Precipitação [soma]; 9: Fotoperíodo [soma]; 10: Genótipos Propósito; 11: Genótipos; 12: NHUR > 90 [sum]; 13: Radiação Solar [soma]; 14: Colheita Decêndio; 15: NDRAD < 10 [sum]; 16: Temperatura Orvalho [soma]; 17: NDTMAX > 30 [sum]; 18: NHUR < 60 [sum]; 19: Solo Textura; 20: Fungicida Planejado [aplicações]; 21: Amplitude Térmica [soma]; 22: Ciclo Semeadura-Colheita [dias]; 23: Umidade Relativa [soma]; 24: NDUR > 90 [sum]; 25: NDUR > 80 [sum]; 26:

Semeadura Decêndio; **27**: NHRAD > 600 [sum]; **28**: Semeadura Data; **29**: Umidade Relativa Máxima [soma]; **30**: Temperatura Ar Máxima [soma]; **31**: NDPREC_00 [sum]; **32**: Temperatura Ar Mínima [soma]; **33**: NDPREC > 5 [sum]; **34**: Inseticida Planejado [aplicações]; **35**: NDUR < 60 [sum]; **36**: Solo Grupo; **37**: NHRAD > 800 [sum]; **38**: UF; **39**: Umidade Relativa Mínima [soma]; **40**: Produtividade Realizada [kg/ha]; **41**: Altitude Média Classe.

4.1.3 Análise dos Filogramas pelo Método SM2

As Figuras 17 e 18 apresentam os filogramas aproveitados do processo anterior, considerando o exemplo da categoria 4C, onde o par q_{14} é analisado. Neste caso, selecionamos os filogramas C1B4C e C1W4C, que contêm o nó-alvo β , representado por **ProdutividadeRealizadakhga**. O SM2 identifica β em cada filograma, extrai toda a sua descendência filogenética e agrupa os resultados em listas categorizadas. Nestas Figuras 17 e 18, a região em vermelho representa essa descendência filogenética para cada caso, destacando as variáveis extraídas, que desempenham um papel fundamental na modelagem.

A presença dessas variáveis tanto no cenário de melhor desempenho (C1B4C) quanto no de pior desempenho (C1W4C) nos permite entender quais delas exercem maior influência sobre o modelo, fornecendo uma base para identificar os fatores mais determinantes para a produtividade. Ao comparar os cenários bons e ruins, conseguimos evidenciar as variáveis cuja influência é mais consistente e diferenciadora entre os casos analisados, permitindo uma interpretação mais refinada das relações existentes no modelo.


Posteriormente, os nós extraídos são unificados na lista **Scriterion**, que reúne as variáveis com relações significativas com β e evidencia as variações dessas relações entre os melhores e piores desempenhos observados. A Tabela 8 detalha os resultados do processo SM2 por categoria e apresenta o conjunto final de 11 variáveis descendentes de β , consolidadas no **Scriterion**.

Tabela 8 – Variáveis Selecionadas pelo SM2 e Scriterion


Cat.	Par q_{li}	Nº	Detalhe de Elementos
2C	(C1B2C, C1W2C)	2	3, 6
4C	(C1B4C, C1W4C)	11	1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11
8C	(C1B8C, C1W8C)	4	3, 6, 8, 11
16C	(C1B16C, C1W16C)	1	8
	Scriterion	11	1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11

Fonte: Elaborada pelo autor.

Codificação: **1**: NHUR<60sum; **2**: AltitudeMediam; **3**: NDTMIN<10sum; **4**: CicloSemeadura-Colheitadias; **5**: NDUR>90sum; **6**: NHTMED<10sum; **7**: NHUR>90sum; **8**: NDUR>80sum; **9**: AltitudeMinimam; **10**: AltitudeMaximam; **11**: NDUR<60sum.

Figura 17 – Filograma C1B4C: Descendência de β no Melhor Desempenho (Par q14)

Fonte: Elaborada pelo autor.

Figura 18 – Filograma C1W4C: Descendência de β no Pior Desempenho (Par q14)

Fonte: Elaborada pelo autor.

4.1.4 Análise do Filograma pelo Método SM3

A Figura 19 apresenta o filograma do problema com 54 variáveis de origem. No SM3, o filograma foi re-enraizado em *ProdutividadeRealizadakhgha* e submetido a uma travessia em ordem de nível, organizando os nós por profundidade.

Foi estabelecido um limite de profundidade igual a 14, definido estrategicamente porque

Variáveis com menor distância copenética possuem maior associação ao objetivo, enquanto distâncias maiores indicam menor relação. Para definir o conjunto final, aplicamos um threshold que inclui até Genotipos, resultando em 46 variáveis armazenadas na lista Scophenetic.

Essa abordagem permite selecionar variáveis altamente relevantes para a modelagem, garantindo uma estrutura robusta e direcionada para análises mais precisas.

Tabela 9 – Distâncias copenéticas de ProdutividadeRealizadakgha a Leaf (da menor para a maior)

Leaf	Distance	Leaf	Distance
NHRAD>600sum	1.9820	AmplitudeTermicasoma	2.0503
NDTMAX>30sum	1.9900	TemperaturaArMinimasoma	2.0511
NDRAD>20sum	1.9906	AltitudeMediam	2.0528
NDPREC=00sum	1.9919	AltitudeMaximam	2.0539
NDPREC>02sum	1.9930	AltitudeMinimam	2.0547
NHRAD>1000sum	1.9975	NDUR>90sum	2.0649
TemperaturaMolhamentoFoliarsoma	2.0078	Precipitacaosoma	2.0656
TemperaturaArNoturnaoC	2.0083	NDUR>80sum	2.0673
TemperaturaOrvalhosoma	2.0097	Talhao	2.0740
TalhaoLatitudeGraudecimal	2.0124	CicloSemeadura-Colheitadias	2.0785
TalhaoLongitudeGraudecimal	2.0129	InseticidaPlanejadoaplicacoes	2.0815
NHRAD>800sum	2.0131	HerbicidaPlanejadoaplicacoes	2.0872
EvapotranspiracaoPotencialPMsoma	2.0163	FungicidaPlanejadoaplicacoes	2.0879
EvapotranspiracaoPotencialPM2soma	2.0165	Fotoperiodosoma	2.1023
NDRAD<10sum	2.0313	Semeaduradata	2.1034
GrausDiassoma	2.0317	UF	2.1086
RadiacaoSolarisoma	2.0323	NDUR<60sum	2.1087
TemperaturaArsoma	2.0331	NDTMIN<10sum	2.1117
UmidadeRelativaMaximasoma	2.0341	Genotipos	2.1138
NDPREC>5sum	2.0342	SoloTextura	2.1215
UmidadeRelativasoma	2.0365	NHTMED<10sum	2.1228
UmidadeRelativaMinimasoma	2.0373	SoloGrupo	2.1312
Colheitadecendio	2.0377	AltitudeMediaclasse	2.1461
NHUR>90sum	2.0463	Colheitadata	2.1525
TemperaturaArMaximasoma	2.0477	GenotiposProposito	2.1802
NHUR<60sum	2.0491	TipoSafr	2.2009
Semeaduradecendio	2.0502		

Fonte: Elaborada pelo autor.

O **rVP** é definido como a fusão dos conjuntos **Sclade**, **Scriterion**, **Soclade** e **Scophenetic**, correspondentes aos resultados dos métodos **SM1**, **SM2**, **SM3** e **SM4**, respectivamente. No entanto, nossa estratégia consistiu em unir **Sclade** com **Scriterion** e **Soclade** com **Scophenetic**, preservando a lógica intrínseca de cada abordagem.


A etapa seguinte envolveu a **interseção** dessas uniões, estabelecendo **rVP** como:

$$rVP = (Sclade \cup Scriterion) \cap (Soclade \cup Scophenetic) \quad (4.1)$$

Essa estratégia garante que apenas as variáveis presentes em ambas as uniões sejam selecionadas, reforçando sua relevância para a modelagem. Por fim, a **Tabela 10** apresenta os

resultados do **rVP**, destacando em **negrito** as **39 variáveis finais**, que representam os elementos mais significativos para o modelo. O processo pode ser refinado em ciclos adicionais (segundo ou terceiro) usando novas análises filogenéticas (SM1, SM2, SM3 e SM4) para reduzir o rVP. Alternativamente, adotamos uma abordagem focada na extração de variáveis dos níveis de complexidade dos membership, permitindo uma análise mais granular e direcionada.

Figura 20 – Árvore Filogenética do rVP: Variáveis Mais Relevantes para o Modelo Final



Fonte: Elaborada pelo autor.

Esta etapa corresponde à fase final para a formação do conjunto **rVP**, cujos resultados estão detalhados na **Tabela 11**. Aproveitamos as agrupações para extrair duas variáveis de cada membership, selecionadas com base na distância copenética a partir do alvo *ProdutividadeRealizada*. O objetivo é reduzir o número de variáveis na formação do **rVP**, garantindo a representatividade de cada agrupação. Dessa forma, a seleção considera não apenas a análise de sensibilidade, a topologia ou a proximidade das variáveis, mas também a complexidade dentro de cada grupo. Isso permite uma seleção equilibrada, incorporando variáveis de diferentes níveis

Tabela 10 – $rVP = (Sclade \cup Scriterion) \cap (Soclade \cup Scophenetic)$

$(Sclade \cup Scriterion)$	$(Soclade \cup Scophenetic)$
AltitudeMaximam	AltitudeMaximam
AltitudeMediaclasse	-
AltitudeMediam	AltitudeMediam
AltitudeMinimam	AltitudeMinimam
AmplitudeTermicasoma	AmplitudeTermicasoma
CicloSemeadura-Colheitadias	CicloSemeadura-Colheitadias
Colheitadata	-
Colheitadecendio	Colheitadecendio
-	EvapotranspiracaoPotencialPM2soma
-	EvapotranspiracaoPotencialPMsoma
Fotoperiodosoma	Fotoperiodosoma
FungicidaPlanejadoaplicacoes	FungicidaPlanejadoaplicacoes
Genotipos	Genotipos
GenotiposProposito	GrausDiassoma
HerbicidaPlanejadoaplicacoes	HerbicidaPlanejadoaplicacoes
InseticidaPlanejadoaplicacoes	InseticidaPlanejadoaplicacoes
NDPREC=00sum	NDPREC=00sum
NDPREC>02sum	NDPREC>02sum
NDPREC>5sum	NDPREC>5sum
NDRAD<10sum	NDRAD<10sum
NDRAD>20sum	NDRAD>20sum
NDTMAX>30sum	NDTMAX>30sum
NDTMIN<10sum	NDTMIN<10sum
NDUR<60sum	NDUR<60sum
NDUR>80sum	NDUR>80sum
NDUR>90sum	NDUR>90sum
NHRAD>1000sum	NHRAD>1000sum
NHRAD>600sum	NHRAD>600sum
NHRAD>800sum	NHRAD>800sum
NHUR<60sum	NHUR<60sum
NHUR>90sum	NHUR>90sum
Precipitacaosoma	Precipitacaosoma
ProdutividadeRealizadakgha	ProdutividadeRealizadakgha
RadiacaoSolarasoma	RadiacaoSolarasoma
Semeaduradata	Semeaduradata
Semeaduradecendio	Semeaduradecendio
SoloGrupo	SoloGrupo
SoloTextura	Talhao
-	TalhaoLatitudegraudecimal
-	TalhaoLongitudegraudecimal
TemperaturaArMaximasoma	TemperaturaArMaximasoma
TemperaturaArMinimasoma	TemperaturaArMinimasoma
-	TemperaturaArNoturnaoC
-	TemperaturaArsoma
-	TemperaturaMolhamentoFoliarsoma
TemperaturaOrvalhosoma	TemperaturaOrvalhosoma
TipoSafra	-
UF	UF
UmidadeRelativaMaximasoma	UmidadeRelativaMaximasoma
UmidadeRelativaMinimasoma	UmidadeRelativaMinimasoma
UmidadeRelativasoma	UmidadeRelativasoma

Fonte: Elaborada pelo autor.

Tabela 11 – Variáveis por Membership

Membership	Variáveis
1	Fotoperiodosoma, Genotipos, Precipitacaosoma, RadiacaoSolarsoma, SoloGrupo, TemperaturaOrvalhosoma
2	Colheitadecendio, NDPREC>5sum, NDRAD<10sum, NDTMIN<10sum, NHRAD>800sum, Semeaduradecendio, UF
3	CicloSemeadura-Colheitadias, NDUR<60sum, NDUR>80sum, NDUR>90sum, NHUR<60sum, NHUR>90sum
4	AltitudeMaximam, AltitudeMediam, AltitudeMinimam
5	FungicidaPlanejadoaplicacoes, HerbicidaPlanejadoaplicacoes, InseticidaPlanejadoaplicacoes
6	NDPREC=00sum, NDPREC>02sum, NDRAD>20sum, NDTMAX>30sum, NHRAD>1000sum, NHRAD>600sum, ProdutividadeRealizadakgha
7	AmplitudeTermicasoma, Semeaduradata, TemperaturaArMaximasoma, TemperaturaArMinimasoma
8	UmidadeRelativaMaximasoma, UmidadeRelativaMinimasoma, UmidadeRelativasoma

Fonte: Elaborada pelo autor.

de complexidade e assegurando uma modelagem mais estruturada e informativa.


As variáveis selecionadas a partir desta análise foram: [Genotipos, RadiacaoSolar-soma], [NHRAD>800sum, NDPREC>5sum], [NHUR>90sum, NHUR<60sum], [AltitudeMediam, AltitudeMaximam], [InseticidaPlanejadoaplicacoes, FungicidaPlanejadoaplicacoes], [NHRAD>600sum, ProdutividadeRealizadakgha], [TemperaturaArMaximasoma, AmplitudeTermicasoma] y [UmidadeRelativaMaximasoma, UmidadeRelativasoma].

Essas variáveis servirão como insumo para o modelo subsequente, baseado no Critério de Complexidade, permitindo sua manipulação e ajuste conforme a necessidade da análise.

4.2 Resultados do Modelo baseado no Phylograma


A Figura 21 apresenta os resultados do filograma para os dados da base sintética *Weak*, onde os memberships observados foram [7, 8], [1, 2, 6], [3, 4, 5, 9], enquanto a estrutura esperada é [1, 2, 5], [3, 7, 8], [4, 6, 9]. Note que os elementos [1, 2], [7, 8] e [4, 9] são resultados parciais que já correspondem, em parte, à estrutura esperada, sugerindo uma aproximação inicial com a estrutura prevista. No entanto, é fundamental considerar que essas agrupações foram formadas sob baixa probabilidade, refletindo uma estrutura frágil na formação dos grupos dentro do filograma gerado pelo DAMICORE.

A Figura 22 apresenta os resultados do filograma para os dados sintéticos *Medium*, onde os memberships observados foram [2, 5], [7, 8], [6, 9] e [1, 3, 4], enquanto a estrutura esperada permanece [1, 2, 5], [3, 7, 8], [4, 6, 9]. Nota-se que os agrupamentos [2, 5], [7, 8] e [6, 9] já apresentam uma correspondência parcial com a estrutura prevista, indicando uma aproximação maior em relação à base *Weak*. No entanto, as diferenças persistentes nos agrupamentos sugerem um comportamento ainda transitório, refletindo uma probabilidade intermediária na formação

Figura 21 – Memberships em Árvore Filogenética para Dados *Weak*


Fonte: Elaborada pelo autor.

dos grupos dentro do modelo gerado pelo DAMICORE.

Figura 22 – Memberships em Árvore Filogenética para Dados *Medium*

Fonte: Elaborada pelo autor.

A Figura 23 apresenta os resultados do filograma para os dados sintéticos *Strong*, onde os memberships observados foram [1, 3, 9], [7, 8], [2, 5] e [4, 6], enquanto a estrutura esperada permanece [1, 2, 5], [3, 7, 8], [4, 6, 9]. Nota-se que os agrupamentos [2, 5], [7, 8] e [4, 6] mantêm correspondência com a estrutura prevista, reforçando indícios de estabilidade na formação desses grupos. Essa proximidade sugere que essas variáveis possuem maior consistência dentro do modelo, alinhando-se progressivamente à organização esperada no DAMICORE.

Figura 23 – Memberships em Árvore Filogenética para Dados *Strong*

Fonte: Elaborada pelo autor.


A Figura 24 apresenta as agrupações das 16 variáveis selecionadas do *rVP*, obtidas a partir da escolha de duas variáveis por membership com base na distância cophenética em relação a *ProdutividadeRealizadakgha*. Considerando apenas essas variáveis no modelo DAMI-CORE, as novas agrupações observadas foram: [*ProdutividadeRealizadakgha*, *NHUR*<60sum, *NDPREC*>5sum], [*TemperaturaArMaximasoma*, *AmplitudeTermicasoma*], [*AltitudeMaximam*, *AltitudeMediam*], [*UmidadeRelativaMaximasoma*, *UmidadeRelativasoma*], [*NHUR*>90sum, *InseticidaPlanejadoaplicacoes*, *Genotipos*, *FungicidaPlanejadoaplicacoes*] e [*NHRAD*>600sum, *RadiacaoSolarsoma*, *NHRAD*>800sum]. Essas agrupações refletem as relações estruturais entre as variáveis dentro do modelo, destacando padrões relevantes na organização filogenética dos dados.

4.3 Resultados do Modelo baseado na Complexidade Combinada

As Tabelas 12, 13 e 14 apresentam um resumo dos cinco melhores, cinco medianos e cinco piores resultados obtidos para os dados sintéticos *Weak*, *Medium* e *Strong*. Em todos os casos, foram realizadas 21.147 iterações, correspondendo ao total de combinações possíveis para 9 variáveis. As tabelas exibem as partições formadas e as respectivas medidas de complexidade do modelo, da população e da complexidade combinada.

A ordenação dos resultados foi feita com base na complexidade combinada, do menor para o maior valor, evidenciando tanto as melhores quanto as piores partições. Notavelmente, em todos os três cenários (*Weak*, *Medium* e *Strong*), a estrutura resultante converge para [[1, 2, 5], [3,

Figura 24 – Memberships em Árvore Filogenética para Dados da FABC



Fonte: Elaborada pelo autor.

7, 8], [4, 6, 9]], a mesma que era esperada, reforçando a consistência do modelo na identificação das agrupações previstas.

Tabela 12 – Resumo dos 5 melhores, 5 medianos e 5 últimos resultados dos dados *Weak*

Index	Partition	C_m	C_p	CC
0	[[1, 2, 5], [3, 7, 8], [4, 6, 9]]	368.79	8760.23	9129.02
1	[[1, 2, 5], [7], [3, 8], [4, 6, 9]]	318.95	8989.34	9308.29
2	[[2], [1, 5], [3, 7, 8], [4, 6, 9]]	318.95	8991.88	9310.83
3	[[1, 2, 5, 7], [3, 8], [4, 6, 9]]	428.59	8984.03	9412.62
4	[[1, 5], [2, 3, 7, 8], [4, 6, 9]]	428.59	8984.34	9412.93
...	...	...	...	...
10571	[[1], [3, 4], [2, 6], [7], [5, 8], [9]]	179.41	10983.64	11163.05
10572	[[1], [3, 4], [2, 5], [7], [6, 8], [9]]	179.41	10983.79	11163.20
10573	[[2, 3], [4], [5], [6], [7], [8], [1, 9]]	179.41	10983.79	11163.20
10574	[[2, 3, 7], [4, 8], [1, 5, 6, 9]]	608.00	10555.20	11163.20
10575	[[1], [2, 3], [4, 7], [5, 8], [6, 9]]	209.31	10953.91	11163.22
...	...	...	...	...
21142	[[6], [1, 2, 3, 4, 5, 7, 8, 9]]	11482.25	8985.13	20467.37
21143	[[1], [2, 3, 4, 5, 6, 7, 8, 9]]	11482.25	9039.17	20521.42
21144	[[8], [1, 2, 3, 4, 5, 6, 7, 9]]	11482.25	9067.34	20549.59

Continua na próxima página...

Tabela 12 – (Continuação) Resumo dos 5 melhores, 5 medianos e 5 últimos resultados dos dados *Weak*

Index	Partition	C_m	C_p	CC
21145	[[4], [1, 2, 3, 5, 6, 7, 8, 9]]	11482.25	9350.39	20832.64
21146	[[1, 2, 3, 4, 5, 6, 7, 8, 9]]	22954.52	8361.16	31315.68

Fonte: Elaborada pelo autor.

Tabela 13 – Resumo dos 5 melhores, 5 medianos e 5 últimos resultados dos dados *Medium*

Index	Partition	C_m	C_p	CC
0	[[1, 2, 5], [3, 7, 8], [4, 6, 9]]	368.79	5911.86	6280.65
1	[[3], [1, 2, 5], [7, 8], [4, 6, 9]]	308.98	6526.91	6835.90
2	[[1, 2, 3, 5], [7, 8], [4, 6, 9]]	528.26	6522.81	7051.07
3	[[1, 2, 5], [7, 8], [3, 4, 6, 9]]	608.00	6524.05	7132.05
4	[[3], [1, 2, 5, 7, 8], [4, 6, 9]]	637.90	6524.22	7162.12
...	...	...	...	...
10571	[[1], [3, 6], [8], [2, 4, 5, 7, 9]]	1016.66	9490.08	10506.74
10572	[[2], [3, 4], [7], [1, 5, 6, 8, 9]]	1016.66	9490.28	10506.93
10573	[[2], [3, 4], [8], [1, 5, 6, 7, 9]]	1016.66	9490.28	10506.93
10574	[[2], [4], [3, 6], [1, 5, 7, 8, 9]]	1016.66	9490.98	10507.64
10575	[[2, 3], [4], [6], [1, 5, 7, 8, 9]]	1016.66	9490.99	10507.65
...	...	...	...	...
21142	[[6], [1, 2, 3, 4, 5, 7, 8, 9]]	11482.25	6888.54	18370.79
21143	[[2], [1, 3, 4, 5, 6, 7, 8, 9]]	11482.25	6888.92	18371.17
21144	[[7], [1, 2, 3, 4, 5, 6, 8, 9]]	11482.25	6889.08	18371.33
21145	[[8], [1, 2, 3, 4, 5, 6, 7, 9]]	11482.25	6889.08	18371.33
21146	[[1, 2, 3, 4, 5, 6, 7, 8, 9]]	22954.52	5889.11	28843.63

Fonte: Elaborada pelo autor.

Tabela 14 – Resumo dos 5 melhores, 5 medianos e 5 últimos resultados dos dados *Strong*

Index	Partition	C_m	C_p	CC
0	[[1, 2, 5], [3, 7, 8], [4, 6, 9]]	368.79	5167.75	5536.53
1	[[4], [1, 2, 5], [3, 7, 8], [6, 9]]	299.02	5885.66	6184.67
2	[[1], [2, 5], [3, 7, 8], [4, 6, 9]]	318.95	5914.92	6233.88
3	[[3], [1, 2, 5], [7, 8], [4, 6, 9]]	308.98	5974.69	6283.67
4	[[1, 2, 5], [3, 4, 7, 8], [6, 9]]	408.66	5882.21	6290.86
...	...	...	...	...

Continua na próxima página...

Tabela 14 – (Continuação) Resumo dos 5 melhores, 5 medianos e 5 últimos resultados dos dados *Strong*

Index	Partition	C_m	C_p	CC
10571	[[2], [4], [1, 3, 7], [6, 8], [5, 9]]	269.12	9294.16	9563.28
10572	[[4, 5], [1, 2, 6, 7, 8], [3, 9]]	468.46	9095.03	9563.49
10573	[[1], [2], [3, 6, 7], [4, 8], [5, 9]]	269.12	9294.42	9563.53
10574	[[1], [2], [4, 7], [3, 6, 8], [5, 9]]	269.12	9294.42	9563.53
10575	[[2], [4, 5], [6], [3, 7], [1, 8, 9]]	269.12	9294.57	9563.69
...	...	...	...	...
21142	[[2], [1, 3, 4, 5, 6, 7, 8, 9]]	11482.25	6126.26	17608.50
21143	[[6], [1, 2, 3, 4, 5, 7, 8, 9]]	11482.25	6127.06	17609.31
21144	[[7], [1, 2, 3, 4, 5, 6, 8, 9]]	11482.25	6127.40	17609.65
21145	[[8], [1, 2, 3, 4, 5, 6, 7, 9]]	11482.25	6127.40	17609.65
21146	[[1, 2, 3, 4, 5, 6, 7, 8, 9]]	22954.52	5127.41	28081.94

Fonte: Elaborada pelo autor.

A Tabela 15 apresenta um resumo dos cinco melhores, cinco medianos e cinco piores resultados obtidos para os dados da Fundação ABC. Foram realizadas 21.147 iterações, representando o total de combinações possíveis para nove variáveis. A tabela exibe as partições formadas e as respectivas medidas de complexidade do modelo, da população e da complexidade combinada.

A ordenação dos resultados foi feita com base na complexidade combinada, do menor para o maior valor, destacando tanto as melhores quanto as piores partições. Observa-se que a melhor partição resultante foi: **[[Altitude Média [m], Altitude Máxima [m]], [Inseticida Planejado [aplicações], Fungicida Planejado [aplicações]], [Genótipos, Produtividade Realizada[kg/ha]], [Radiação Solar [soma], NHRAD > 600 [sum], Umidade Relativa Máxima [soma]]**. Essa partição apresenta convergência parcial com os memberships identificados pelo modelo DAMICORE, que são: **[[ProdutividadeRealizada<kg/ha, NHUR<60sum, NDPREC>5sum], [TemperaturaArMaximasoma, AmplitudeTermicasoma], [AltitudeMaximam, AltitudeMediam], [UmidadeRelativaMaximasoma, UmidadeRelativasoma], [NHUR>90sum, InseticidaPlanejado-aplicacoes, Genotipos, FungicidaPlanejadoaplicacoes] e [NHRAD>600sum, RadiacaoSolar-soma, NHRAD>800sum]]**.

Essa proximidade sugere uma estrutura coerente entre os diferentes métodos, evidenciando a relação entre as variáveis identificadas pela abordagem DAMICORE e aquelas obtidas pela análise baseada na complexidade combinada.

Tabela 15 – Resumo dos 5 melhores, 5 medianos e 5 últimos resultados dos dados da FABC

Index	Partition	C_m	C_p	CC
0	[[3, 4], [5, 6], [1, 8], [2, 7, 9]]	760.45	24408.04	25168.48
1	[[1], [3, 4], [5, 6], [8], [2, 7, 9]]	581.52	24638.61	25220.13
2	[[1], [3, 4], [5, 6, 8], [2, 7, 9]]	760.45	24535.52	25295.97
3	[[1], [5, 6], [3, 4, 8], [2, 7, 9]]	760.45	24538.03	25298.47
4	[[5], [3, 4, 6], [1, 8], [2, 7, 9]]	894.64	24444.86	25339.51
...	...	...	...	...
10571	[[1], [2, 4, 6], [3, 7], [5, 8, 9]]	760.45	28801.91	29562.35
10572	[[1, 3], [7], [6, 8], [2, 4, 5, 9]]	1297.23	28265.15	29562.38
10573	[[3], [2, 4], [6], [7], [1, 8], [5, 9]]	536.79	29025.63	29562.41
10574	[[4], [1, 3, 5], [6, 7, 8], [2, 9]]	1297.23	28265.21	29562.44
10575	[[1], [2, 3], [5], [6], [7, 8], [4, 9]]	402.59	29159.90	29562.49
...	...	...	...	...
21142	[[4], [1, 2, 3, 5, 6, 7, 8, 9]]	220126.47	22360.41	242486.87
21143	[[7], [1, 2, 3, 4, 5, 6, 8, 9]]	220126.47	22438.68	242565.15
21144	[[3], [1, 2, 4, 5, 6, 7, 8, 9]]	220126.47	22449.24	242575.70
21145	[[2], [1, 3, 4, 5, 6, 7, 8, 9]]	220126.47	22533.96	242660.42
21146	[[1, 2, 3, 4, 5, 6, 7, 8, 9]]	660334.67	19855.53	680190.20

Fonte: Elaborada pelo autor.

Codificação: 1: Genótipos; 2: Radiação Solar [soma]; 3: Altitude Média [m]; 4: Altitude Máxima [m]; 5: Inseticida Planejado [aplicações]; 6: Fungicida Planejado [aplicações]; 7: NH.RAD > 600 [sum]; 8: Produtividade Realizada [kg/ha]; 9: Umidade Relativa Máxima [soma].


A Figura 25 apresenta a Complexidade Combinada, organizada em dois gráficos empilhados. O gráfico superior mostra a evolução geral da CC ao longo dos índices, enquanto o gráfico inferior detalha configurações menos complexas. Os pontos azuis indicam os valores calculados para cada índice, com um aumento gradual que reflete a transição de configurações simples para mais complexas. Os pontos vermelhos destacam configurações relevantes identificadas no modelo.

No gráfico superior, os valores de CC ultrapassam 30.000, representando as configurações mais complexas, como [[1, 2, 3, 4, 5, 6, 7, 8, 9]], onde todas as variáveis são agrupadas em um único Building Block. No gráfico inferior, destacam-se duas faixas: entre 10.000 e 12.000, aparecem agrupamentos intermediários como [[1], [3, 4], [2, 6], [7], [5, 8], [9]]; já entre 9.000 e 9.500, encontra-se o melhor modelo, representado por [[1, 2, 5], [3, 7, 8], [4, 6, 9]].

Essa organização dos gráficos permite identificar padrões globais e analisar em detalhe agrupamentos específicos. As configurações destacadas são estratégicas para o desempenho do modelo, oferecendo insights importantes para sua otimização.

A Figura 25 apresentou a análise da CC considerando a distribuição dos Building Blocks

Figura 25 – Análise da CC dos Dados Weak: Evolução e Configurações Otimizadas em BBs



Fonte: Elaborada pelo autor.

e sua evolução ao longo dos índices. A organização em dois gráficos empilhados permitiu identificar padrões globais e destacar configurações estratégicas com impacto no modelo.


Seguindo a mesma abordagem, a Figura 26 aprofunda essa análise ao identificar uma nova configuração de variáveis, onde o agrupamento mais complexo atingiu valores próximos a 30.000, enquanto as configurações intermediárias ficaram entre 10.000 e 12.000. O melhor modelo identificado situou-se na faixa entre 6.000 e 6.500, evidenciando um agrupamento estruturado em 3 Building Blocks [[1, 2, 5], [3, 7, 8], [4, 6, 9]].

Agora, a Figura 27 dá continuidade à investigação, mantendo a estrutura dos gráficos empilhados para facilitar a comparação e destacar padrões recorrentes. Nessa nova configuração, observa-se que o agrupamento mais complexo, onde todas as variáveis estão reunidas em um único Building Block [[1, 2, 3, 4, 5, 6, 7, 8, 9]], atinge valores próximos a 28.000.

No gráfico inferior, destacam-se duas faixas distintas: entre 8.000 e 11.000, aparecem agrupamentos intermediários, como [[1], [2, 5], [3, 7], [4, 6, 8], [9]], refletindo uma organização mais estruturada das variáveis. Já em 5.500, encontra-se o melhor modelo identificado, que mantém uma segmentação estável similar à da Figura 5 e 6, estruturada como [[1, 2, 5], [3, 7, 8], [4, 6, 9]].

Essa progressão de resultados permite uma análise aprofundada da CC e evidencia como

Figura 26 – Análise da CC dos Dados Medium: Evolução e Configurações Otimizadas em BBs



Fonte: Elaborada pelo autor.


as configurações dos Building Blocks evoluem, fornecendo insights para a otimização do modelo.

A Figura 28 apresenta a CC em dois gráficos empilhados. O gráfico superior mostra a evolução geral da CC, com o agrupamento de todas as variáveis atingindo 700.000, representando a configuração mais complexa. O gráfico inferior detalha configurações menos complexas, destacando faixas entre 27.000 e 33.000, com agrupamentos intermediários, e em 25.100, onde está o melhor modelo, incluindo combinações como ['Altitude Média [m]', 'Altitude Máxima [m]'] e ['Inseticida Planejado [aplicações]', 'Fungicida Planejado [aplicações]'].

As Figuras permitem identificar padrões e configurações importantes para otimizar o modelo.


Codificação: 1: Genótipos; 2: Radiação Solar [soma]; 3: Altitude Média [m]; 4: Altitude Máxima [m]; 5: Inseticida Planejado [aplicações]; 6: Fungicida Planejado [aplicações]; 7: NH.RAD > 600 [sum]; 8: Produtividade Realizada [kg/ha]; 9: Umidade Relativa Máxima [soma].

Figura 27 – Análise da CC dos Dados Strong: Evolução e Configurações Otimizadas em BBs



Fonte: Elaborada pelo autor.

Figura 28 – Análise da CC dos Dados da FABC: Evolução e Configurações Otimizadas em BBs



Fonte: Elaborada pelo autor.

CONCLUSÕES PRELIMINARES

Este estudo demonstrou a eficácia de uma metodologia inovadora para análise de dados heterogêneos, comparamos as abordagens SM1, SM2, SM3 e SM4 para a modelagem da Produtividade Realizada (kg/ha) e identificamos que a interseção entre os conjuntos $S_{\text{clade}} \cup S_{\text{criterion}}$ e $S_{\text{oclade}} \cup S_{\text{cophenetic}}$ possibilitou a seleção de um subconjunto reduzido, mas altamente informativo, de variáveis. Essa redução dimensional foi fundamental para destacar as variáveis-chave de natureza agrometeorológica, edáfica e genotípica, as quais se mostraram determinantes para o desempenho do sistema analisado.

Adicionalmente, os agrupamentos ou blocos de construção finais obtidos pelos modelos DAMICORE e a abordagem baseada no CCC mostraram alta consistência com as estruturas teóricas previstas. Essa convergência, validada tanto em experimentos com dados sintéticos quanto em dados reais fornecidos pela Fundação ABC, reforça a robustez do CCC na recuperação de padrões alinhados a métodos tradicionais de modelagem probabilística.

Além disso, o uso desses blocos em modelos preditivos, por meio de Algoritmos de Estimação de Distribuição ou modelos gráficos probabilísticos dirigidos, propiciará que os modelos sejam não apenas interpretáveis e explicáveis, mas também potencialmente causais e transportáveis. Tal característica é especialmente relevante para a produtividade agrícola, pois experimentos bem-sucedidos em uma região específica podem não se reproduzir em outras localidades ou períodos. A Fundação ABC forneceu um conjunto de dados heterogêneos singular, o que viabilizou a exploração de modelos estruturais, demonstrando a aplicabilidade da metodologia proposta em diferentes cenários espaciais e temporais.

Por fim, a integração entre a análise filogenética e os blocos de construção do CCC revelou-se altamente eficaz. Essa sinergia promove uma modelagem mais parcimoniosa, alinhada aos princípios da teoria da informação e dos modelos probabilísticos. Os resultados obtidos não apenas validam a aplicabilidade multidisciplinar da abordagem proposta, mas também abrem novas oportunidades para o estudo de sistemas complexos e dados heterogêneos.

CRONOGRAMA

6.1 Cronograma de Atividades

Será realizado um conjunto de atividades essenciais para a conclusão do projeto de pesquisa. Esse conjunto de atividades inclui revisão da literatura, modelagem, implementação, redação de artigos científicos e testes experimentais em laboratório (simulação) e em cenários reais.

Além disso, a participação em eventos acadêmicos será fundamental para a divulgação dos avanços desta pesquisa e para o intercâmbio de ideias com a comunidade científica. Essas atividades permitirão validar os resultados e aprimorar a abordagem proposta.

Tabela 16 – Atividades de Pesquisa e Cronograma.

Atividade	2023		2024		2025		2026		2027	
	I	II	I	II	I	II	I	II	I	II
Cumprimento dos requisitos acadêmicos	X	X	X	X						
Revisão sistemática da literatura			X	X						
Reuniões interdisciplinares com especialistas da FABC			X	X						
Desenvolvimento do Projeto de Pesquisa (Qualificação)			X	X	X					
Modelagem e desenvolvimento da abordagem proposta			X	X	X					
- Modelo baseado na análise filogenética (SM1, SM2, SM3, SM4)				X	X	X				
- Modelo baseado no CCC					X	X				
- Comparação e avaliação entre os modelos propostos					X	X				

REFERÊNCIAS

- ANDREADIS, G.; ALDERLIESTEN, T.; BOSMAN, P. A. Fitness-based linkage learning and maximum-clique conditional linkage modelling for gray-box optimization with rv-gomea. In: **Proceedings of the Genetic and Evolutionary Computation Conference**. [S.l.: s.n.], 2024. p. 647–655. Citado na página 24.
- BRANCO, H. M. G. C.; SILVA, R. da; OLESKOVICZ, M.; COURY, D. V.; DELBEM, A. C. B. Extended compact genetic algorithm applied for optimum allocation of power quality monitors in transmission systems. In: IEEE. **2011 IEEE Power and Energy Society General Meeting**. [S.l.], 2011. p. 1–6. Citado nas páginas 30, 31 e 85.
- CHEN, C.-H.; LIU, W.-N.; CHEN, Y.-P. Adaptive discretization for probabilistic model building genetic algorithms. In: **Proceedings of the 8th annual conference on Genetic and evolutionary computation**. [S.l.: s.n.], 2006. p. 1103–1110. Citado nas páginas 31 e 85.
- CHEN, Y.-p.; CHEN, C.-H. Enabling the extended compact genetic algorithm for real-parameter optimization by using adaptive discretization. **Evolutionary Computation**, MIT Press One Rogers Street, Cambridge, MA 02142-1209, USA journals-info . . . , v. 18, n. 2, p. 199–228, 2010. Citado nas páginas 31 e 84.
- CHUANG, C.-Y.; CHEN, Y.-p. Sensibility of linkage information and effectiveness of estimated distributions. **Evolutionary Computation**, MIT Press One Rogers Street, Cambridge, MA 02142-1209, USA journals-info . . . , v. 18, n. 4, p. 547–579, 2010. Citado nas páginas 30, 31 e 84.
- CHUANG, C.-Y.; HSU, W.-L. Multivariate multi-model approach for globally multimodal problems. In: **Proceedings of the 12th annual conference on Genetic and evolutionary computation**. [S.l.: s.n.], 2010. p. 311–318. Citado nas páginas 31 e 87.
- CHUANG, C.-Y.; SMITH, S. F. Diversity allocation for dynamic optimization using the extended compact genetic algorithm. In: IEEE. **2013 IEEE Congress on Evolutionary Computation**. [S.l.], 2013. p. 1540–1547. Citado nas páginas 31 e 88.
- DUQUE, T.; SASTRY, K.; DELBEM, A. C.; GOLDBERG, D. E. Evolutionary algorithm for large scale problems. In: IEEE. **Seventh International Conference on Intelligent Systems Design and Applications (ISDA 2007)**. [S.l.], 2007. p. 819–822. Citado na página 84.
- DUQUE, T. S.; GOLDBERG, D. E.; SASTRY, K. Improving the efficiency of the extended compact genetic algorithm. In: **Proceedings of the 10th annual conference on Genetic and evolutionary computation**. [S.l.: s.n.], 2008. p. 467–468. Citado nas páginas 24, 48 e 89.
- FUNDACAOABC. 2025. <<https://fundacaoabc.org/>>. Fundação ABC, s.d. Acesso em: 11 fev. 2025. Citado na página 35.
- GASPAR-CUNHA, A.; MONACO, F.; SIKORA, J.; DELBEM, A. Artificial intelligence in single screw polymer extrusion: Learning from computational data. **Engineering Applications of Artificial Intelligence**, Elsevier, v. 116, p. 105397, 2022. Citado na página 38.
- GIL, A. C. **Como elaborar projetos de pesquisa**. [S.l.]: Editora Atlas SA, 2002. Citado na página 33.

- GOLDBERG, D. E. **The design of innovation: Lessons from and for competent genetic algorithms**. [S.l.]: Springer, 2002. v. 1. Citado na página 23.
- GOLDBERG, K. S. D. On extended compact genetic algorithm. 2000. Citado na página 51.
- HARIK, G. Linkage learning via probabilistic modeling in the ecga. **IIIiGAL Report**, n. 99010, 1999. Citado nas páginas 24, 48 e 49.
- HARIK, G. R.; LOBO, F. G.; SASTRY, K. Linkage learning via probabilistic modeling in the extended compact genetic algorithm (ecga). In: **Scalable optimization via probabilistic modeling**. [S.l.]: Springer, 2006. p. 39–61. Citado nas páginas 30, 31, 48 e 86.
- HARTEMINK, A. J. **Principled computational methods for the validation discovery of genetic regulatory networks**. Tese (Doutorado) — Massachusetts Institute of Technology, 2001. Citado nas páginas 35, 46 e 47.
- HOLLAND, J. H. **Adaptation in natural and artificial systems: an introductory analysis with applications to biology, control, and artificial intelligence**. [S.l.]: MIT press, 1992. Citado na página 23.
- ICLANZAN, D. Higher-order linkage learning in the ecga. In: **Proceedings of the 14th annual conference on Genetic and evolutionary computation**. [S.l.: s.n.], 2012. p. 265–272. Citado nas páginas 31 e 88.
- ICLANZAN, D.; DUMITRESCU, D.; HIRSBRUNNER, B. Correlation guided model building. In: **Proceedings of the 11th Annual conference on Genetic and evolutionary computation**. [S.l.: s.n.], 2009. p. 421–428. Citado nas páginas 31 e 86.
- KHARRAT, F. G. Z.; DELBEM, A. C. B. Fs-opa: Combination of optimization based on phylogram analysis and cox regression applied to mental disorder datasets. 2019. Citado na página 42.
- KHARRAT, F. G. Z.; MIYOSHI, N. S. B.; COBRE, J.; AZEVEDO-MARQUES, J. M. D.; AZEVEDO-MARQUES, P. Mazzoncini de; DELBEM, A. C. B. Feature sensitivity criterion-based sampling strategy from the optimization based on phylogram analysis (fs-opa) and cox regression applied to mental disorder datasets. **Plos one**, Public Library of Science San Francisco, CA USA, v. 15, n. 7, p. e0235147, 2020. Citado nas páginas 42, 43 e 44.
- KITCHENHAM, B.; CHARTERS, S. *et al.* **Guidelines for performing systematic literature reviews in software engineering**. [S.l.]: UK, 2007. Citado na página 25.
- LANZI, P. L.; NICHETTI, L.; SASTRY, K.; VOLTINI, D.; GOLDBERG, D. E. Real-coded extended compact genetic algorithm based on mixtures of models. **Linkage in evolutionary computation**, Springer, p. 335–358, 2008. Citado nas páginas 31 e 86.
- LI, J.; SONG, Y. Community detection in complex networks using extended compact genetic algorithm. **Soft computing**, Springer, v. 17, p. 925–937, 2013. Citado nas páginas 30 e 88.
- LI, M.; CHEN, X.; LI, X.; MA, B.; VITÁNYI, P. M. The similarity metric. **IEEE transactions on Information Theory**, IEEE, v. 50, n. 12, p. 3250–3264, 2004. Citado na página 38.
- LIMA, C. F.; FERNANDES, C.; LOBO, F. G. Investigating restricted tournament replacement in ecga for non-stationary environments. In: **Proceedings of the 10th annual conference on Genetic and evolutionary computation**. [S.l.: s.n.], 2008. p. 439–446. Citado nas páginas 31 e 88.
- LIMA, C. F.; SASTRY, K.; GOLDBERG, D. E.; LOBO, F. G. Combining competent crossover and mutation operators: A probabilistic model building approach. In: **Proceedings of the 7th annual conference on Genetic and evolutionary computation**. [S.l.: s.n.], 2005. p. 735–742. Citado nas páginas 30, 31 e 85.

LIU, H.; HUSSAIN, F.; TAN, C. L.; DASH, M. Discretization: An enabling technique. **Data mining and knowledge discovery**, Springer, v. 6, p. 393–423, 2002. Citado na página 46.

LOPES, G. R. Multimapas: abordagem multiobjetivo para construção de mapas coropléticos de dados heterogêneos multifontes. 2023. Citado na página 17.

LOPES, G. R.; DELBEM, A. C.; SILVA, R. F. da; JÚNIOR, C. B.; MATTOS, S. H. V. L. de; SCATOLINI, D.; GHIGLIENO, F.; SARAIVA, A. M. Multimaps: a tool for decision-making support in the analyzes of multiple epidemics. In: **Proceedings of the 3rd ACM SIGSPATIAL International Workshop on Spatial Computing for Epidemiology**. [S.l.: s.n.], 2022. p. 22–25. Citado na página 23.

MARTINS, J. P.; NETO, C. B.; CROCOMO, M. K.; VITTORI, K.; DELBEM, A. C. A comparison of linkage-learning-based genetic algorithms in multidimensional knapsack problems. In: IEEE. **2013 IEEE Congress on Evolutionary Computation**. [S.l.], 2013. p. 502–509. Citado na página 87.

MUNETOMO, M.; SATAKE, Y.; AKAMA, K. An intelligent scatter with estimation of distribution for tabu search. In: SPRINGER. **Computer Aided Systems Theory–EUROCAST 2007: 11th International Conference on Computer Aided Systems Theory, Las Palmas de Gran Canaria, Spain, February 12-16, 2007, Revised Selected Papers 11**. [S.l.], 2007. p. 465–472. Citado nas páginas 31 e 85.

NEWMAN, M. E. Fast algorithm for detecting community structure in networks. **Physical Review E—Statistical, Nonlinear, and Soft Matter Physics**, APS, v. 69, n. 6, p. 066133, 2004. Citado na página 40.

OH, S.; AHN, C. W. Evolutionary approach for interpretable feature selection algorithm in manufacturing industry. **IEEE Access**, IEEE, v. 11, p. 46604–46614, 2023. Citado nas páginas 30 e 84.

PARSIFAL. **Support to Perform Systematic Literature Reviews**. 2020. <<https://parsif.al/>>. Citado na página 27.

PELIKAN, M.; GOLDBERG, D. E.; LOBO, F. G. A survey of optimization by building and using probabilistic models. **Computational optimization and applications**, Springer, v. 21, p. 5–20, 2002. Citado na página 47.

PETERSEN, K.; VAKKALANKA, S.; KUZNIARZ, L. Guidelines for conducting systematic mapping studies in software engineering: An update. **Information and software technology**, Elsevier, v. 64, p. 1–18, 2015. Citado na página 25.

PRZEWOZNICZEK, M. W.; FREJ, B.; KOMARNICKI, M. M. From direct to directional variable dependencies–non-symmetrical dependencies discovery in real-world and theoretical problems. **IEEE Transactions on Evolutionary Computation**, IEEE, 2024. Citado na página 24.

RISSANEN, J. Modeling by shortest data description. **Automatica**, Elsevier, v. 14, n. 5, p. 465–471, 1978. Citado na página 48.

SAITOU, N.; NEI, M. The neighbor-joining method: a new method for reconstructing phylogenetic trees. **Molecular biology and evolution**, v. 4, n. 4, p. 406–425, 1987. Citado nas páginas 38 e 40.

SANTANA, R.; LARRANAGA, P.; LOZANO, J. A. Learning factorizations in estimation of distribution algorithms using affinity propagation. **Evolutionary Computation**, MIT Press, v. 18, n. 4, p. 515–546, 2010. Citado na página 86.

SASTRY, K.; GOLDBERG, D. E.; JOHNSON, D. Scalability of a hybrid extended compact genetic algorithm for ground state optimization of clusters. **Materials and Manufacturing Processes**, Taylor & Francis, v. 22, n. 5, p. 570–576, 2007. Citado nas páginas 31 e 87.

SHAO, C.-Y.; YU, T.-L. Speeding up model building for ecga on cuda platform. In: **Proceedings of the 15th annual conference on Genetic and evolutionary computation**. [S.l.: s.n.], 2013. p. 1197–1204. Citado na página [48](#).

VERMA, A.; LLORA, X.; VENKATARAMAN, S.; GOLDBERG, D. E.; CAMPBELL, R. H. Scaling ecga model building via data-intensive computing. In: IEEE. **IEEE congress on evolutionary computation**. [S.l.], 2010. p. 1–8. Citado nas páginas [31](#), [48](#) e [87](#).

WANG, W.; JING, L. One-step incremental multi-view spectral clustering based on graph linkage learning. **Neurocomputing**, Elsevier, v. 590, p. 127740, 2024. Citado na página [24](#).

ESTUDOS PRIMÁRIOS SELECIONADOS

Tabela 17 – Estudos Primários Selecionados para Revisão Sistemática

ID	Título do Estudo	Fonte	Objetivo	Metodologia	Resultados	Aplicações	Limitações
1	Sensibility of Linkage Information and Effectiveness of Estimated Distributions (CHUANG; CHEN, 2010)	IEEE	Investigar como o ECGA pode identificar blocos de construção em problemas com escalas desiguais.	Uso de pruning no modelo probabilístico para melhorar a detecção de linkage.	Melhoria significativa em problemas com subproblemas de relevâncias desiguais.	Otimização evolutiva, problemas com múltiplos subproblemas ou partes com pesos distintos.	Testado apenas em problemas aditivamente separáveis; dependência de ajustes de parâmetros.
2	Enabling the Extended Compact Genetic Algorithm for Real-Parameter Optimization by Using Adaptive Discretization (CHEN; CHEN, 2010)	IEEE	Estender o ECGA para variáveis contínuas usando discretização adaptativa (SoD).	Integração do SoD ao ECGA para resolver problemas reais.	Desempenho competitivo em funções de teste e problemas reais.	Otimização de variáveis contínuas em problemas de engenharia que exijam alta precisão.	Dependência de ajustes de parâmetros; não testado em alta dimensionalidade.
3	Evolutionary Algorithm for Large Scale Problems (DUQUE <i>et al.</i> , 2007)	IEEE	Reduzir custos computacionais do ECGA para problemas de larga escala.	Uso de hillclimber e chromosome compression.	Redução significativa do tamanho populacional necessário.	Otimização combinatória de larga escala.	Testado apenas em problemas de referência; maior complexidade de implementação.
4	Evolutionary Approach for Interpretable Feature Selection Algorithm in Manufacturing Industry (OH; AHN, 2023)	IEEE	Propor um método de seleção de características interpretável.	Uso do ECGA para aprender linkages entre variáveis.	Desempenho superior a outros métodos metaheurísticos.	Manufatura, detecção de falhas, previsão de consumo de energia.	Alto custo computacional em alta dimensionalidade.

Tabela 17 – Estudos Primários Seleccionados para Revisão Sistemática (continuação)

ID	Título do Estudo	Fonte	Objetivo	Metodologia	Resultados	Aplicações	Limitações
5	Extended Compact Genetic Algorithm Applied for Optimum Allocation of Power Quality Monitors in Transmission Systems (BRANCO <i>et al.</i> , 2011)	IEEE	Alocação ótima de monitores de qualidade de energia.	Modelagem multiobjetivo via ECGA.	Convergência rápida e menor custo.	Monitoramento de redes elétricas.	Escalabilidade para sistemas muito grandes precisa ser investigada.
6	Combining Competent Crossover and Mutation Operators: A Probabilistic Model Building Approach (LIMA <i>et al.</i> , 2005)	ACM	Combinar crossover e mutação competentes em algoritmos genéticos.	Uso do heCGA com BB-wise crossover e mutação.	Robustez em problemas enganosos, escalonados e ruidosos.	Problemas combinatórios complexos.	Assume blocos de construção não sobrepostos.
7	An Intelligent Scatter with Estimation of Distribution for Tabu Search (MUNETOMO; SATAKE; AKAMA, 2007)	ACM	Guiar a busca tabu com EDAs para problemas multimodais.	Uso do ECGA para gerar pontos iniciais promissores.	Maior eficiência e capacidade de escapar de ótimos locais.	Problemas combinatórios complexos.	Captura principalmente relações lineares.
8	Adaptive Discretization for Probabilistic Model Building Genetic Algorithms (CHEN; LIU; CHEN, 2006)	ACM	Resolver problemas contínuos com discretização adaptativa.	Uso do método SoD integrado ao ECGA.	Escalabilidade subquadrática.	Engenharia e bioinformática.	Presume combinações gaussianas.

Tabela 17 – Estudos Primários Selecionados para Revisão Sistemática (continuação)

ID	Título do Estudo	Fonte	Objetivo	Metodologia	Resultados	Aplicações	Limitações
9	Linkage Learning via Probabilistic Modeling in the Extended Compact Genetic Algorithm (ECGA) (HARIK; LOBO; SASTRY, 2006)	Scopus	Apresentar o ECGA como uma abordagem para aprender linkage.	Uso de MPMs e critério MDL.	Eficiência em problemas enganosos.	Otimização combinatória.	Assume partições sem sobreposição.
10	Correlation Guided Model Building (ICĂLNZAN; DUMITRESCU; HIRSBRUNNER, 2009)	ACM	Guiar fusões de partições via análise de correlação.	Uso de correlação Pearson.	Redução significativa no número de avaliações.	Otimização combinatória de grande escala.	Captura principalmente relações lineares.
11	Real-Coded Extended Compact Genetic Algorithm Based on Mixtures of Models (LANZI <i>et al.</i> , 2008)	Scopus	Estender o ECGA para variáveis contínuas.	Uso de misturas de distribuições normais.	Escalabilidade subquadrática.	Engenharia e bioinformática.	Presume combinações gaussianas.
12	Learning Factorizations in Estimation of Distribution Algorithms Using Affinity Propagation (SANTANA; LARRANAGA; LOZANO, 2010)	Scopus	Aprender fatorizações usando propagação de afinidade.	Uso do AffEDA.	Superou o ECGA em problemas de alta cardinalidade.	Bioinformática e otimização combinatória.	Pode não capturar interações não-lineares de alta ordem.

Tabela 17 – Estudos Primários Seleccionados para Revisão Sistemática (continuação)

ID	Título do Estudo	Fonte	Objetivo	Metodologia	Resultados	Aplicações	Limitações
13	Scaling eCGA Model Building via Data-Intensive Computing (VERMA <i>et al.</i> , 2010)	IEEE	Escalar o ECGA usando técnicas de computação intensiva em dados.	Implementação em Hadoop e MongoDB.	Redução significativa no tempo de execução.	Otimização em larga escala.	Instabilidade do MongoDB em grande escala.
14	A Comparison of Linkage-learning-based Genetic Algorithms in Multidimensional Knapsack Problems (MARTINS <i>et al.</i> , 2013)	IEEE	Comparar algoritmos baseados em linkage learning no MKP.	Comparação entre eCGA, BOA e LTGA.	LTGA e eCGA foram os mais robustos.	Alocação de recursos e otimização combinatória.	Estrutura dos blocos de construção não é conhecida no MKP.
15	Multivariate Multi-Model Approach for Globally Multimodal Problems (CHUANG; HSU, 2010)	Scopus	Lidar com problemas globalmente multimodais.	Construção de múltiplos modelos probabilísticos simultaneamente.	Encontrou mais ótimos globais que o eCGA convencional.	Planejamento de rotas e modelagem química.	Complexidade computacional elevada.
16	Scalability of a Hybrid Extended Compact Genetic Algorithm for Ground State Optimization of Clusters (SASTRY; GOLDBERG; JOHNSON, 2007)	Scopus	Otimizar clusters atômicos usando hibridização com Nelder-Mead simplex.	Hibridização com busca local.	Redução significativa no número de avaliações.	Ciência dos materiais.	Limitado a clusters pequenos.

Tabela 17 – Estudos Primários Selecionados para Revisão Sistemática (continuação)

ID	Título do Estudo	Fonte	Objetivo	Metodologia	Resultados	Aplicações	Limitações
17	Community detection in complex networks using extended compact genetic algorithm (LI; SONG, 2013)	Scopus	Detectar comunidades em redes complexas.	Uso do ECGA com modularidade Q.	Superou outros algoritmos em redes sintéticas e reais.	Análise de redes sociais e biológicas.	Tempo de execução maior que CNM.
18	Diversity Allocation for Dynamic Optimization using the Extended Compact Genetic Algorithm (CHUANG; SMITH, 2013)	IEEE	Manter diversidade no ECGA para problemas dinâmicos.	Uso de scattering subestrutural.	Melhor desempenho que métodos baseados em RTR.	Otimização dinâmica.	Dependência da taxa de mudança do ambiente.
19	Investigating Restricted Tournament Replacement in ECGA for Non-Stationary Environments (LIMA; FERNANDES; LOBO, 2008)	IEEE	Incorporar RTR no ECGA para ambientes não estacionários.	Uso de RTR tradicional e subestrutural.	RTR subestrutural foi mais eficiente.	Otimização dinâmica.	Requer ajuste de parâmetros.
20	Higher-Order Linkage Learning in the ECGA (ICLANZAN, 2012)	ACM	Detectar dependências de ordem superior usando XOR.	Destilação de entropia baseada em XOR.	Identificação correta de ligações complexas.	Otimização combinatória e aprendizado de máquina.	Custo computacional elevado para grandes valores de k.

Tabela 17 – Estudos Primários Seleccionados para Revisão Sistemática (continuação)

ID	Título do Estudo	Fonte	Objetivo	Metodologia	Resultados	Aplicações	Limitações
21	Improving the Efficiency of the Extended Compact Genetic Algorithm (DUQUE; GOLDBERG; SASTRY, 2008)	ACM	Melhorar a eficiência do ECGA.	Redução de complexidade e hibridização com busca local.	Redução de até 1000 vezes no tempo de execução.	Otimização de larga escala.	Testado apenas em problemas do tipo trap.

PSEUDOCÓDIGOS

Algoritmo 1 – SM1

```

1: função PROC_ARVORES(CA)
2:    $(F1, F2) \leftarrow \text{ECML}(CA)$                                 ▷ Encontrar Caminho Mais Longo
3:    $Cam \leftarrow \text{OBTC}(F1, F2)$                                 ▷ Obter Caminho
4:    $NC \leftarrow \text{ENC}(Cam)$                                     ▷ Encontrar Nó Central
5:   se  $NC \neq \text{Raiz}$  então
6:      $(C1, C2) \leftarrow \text{DIVC}(NC)$                             ▷ Dividir Clados
7:   senão
8:      $(C1, C2) \leftarrow (\text{NULO}, \text{NULO})$ 
9:   fim se
10:   $(AMC, IM) \leftarrow \text{EIM}(CA)$                                 ▷ Encontrar Intersecao Máxima
11:   $NS \leftarrow \text{SNMI}(C1, C2)$                                 ▷ Selecionar Nodos com Mudança de Irmãos
12:   $S\text{Clade} \leftarrow \emptyset$                                 ▷ Inicializar conjunto para acumular resultados por categoria
13:  para todo  $cat \in \{2C, 4C, 8C, 16C\}$  faça                                ▷ Percorrer cada categoria
14:     $S\text{Clade} \leftarrow S\text{Clade} \cup \text{PROCESSCAT}(T_{cat})$     ▷ Acumular resultados da categoria  $cat$ 
15:  fim para
16:  retorna  $(S\text{Clade})$                                 ▷ Retornar a união dos conjuntos em SClade
17: fim função

```

Algoritmo 2 – SM2

```

1: função PROC_BETA( $T, \beta$ )
2:    $BT \leftarrow \emptyset$  ▷ Inicializar conjunto de rótulos das árvores que contêm  $\beta$ 
3:   para todo  $(L, Tree) \in T$  faça ▷ Percorrer todas as árvores
4:     se HASBETA( $Tree, \beta$ ) então ▷ Verificar se a árvore contém  $\beta$ 
5:        $BT \leftarrow BT \cup \{L\}$  ▷ Adicionar rótulo da árvore que contém  $\beta$ 
6:     fim se
7:   fim para
8:    $SCriterion \leftarrow \emptyset$  ▷ Inicializar o conjunto de critério (SCriterion)
9:   para todo  $cat \in \{2C, 4C, 8C, 16C\}$  faça ▷ Percorrer cada categoria
10:     $SCriterion \leftarrow SCriterion \cup \text{BUILDSC}(T_{cat}, \beta)$  ▷ Acumular SCriterion para a
    categoria  $cat$ 
11:   fim para
12:    $SCriterion \leftarrow SCriterion \setminus \{\beta\}$  ▷ Excluir  $\beta$  do SCriterion final
13:   retorna ( $SCriterion$ ) ▷ Retornar a união dos conjuntos em SCriterion
14: fim função

```

Algoritmo 3 – SM3

```

1: função SM3( $Tree, Target, Threshold$ )
2:    $L \leftarrow \text{ENCONTRAFOLHA}(Tree, Target)$  ▷ Encontrar nó folha Target
3:    $\text{SETOUTGROUP}(Tree, L[0])$  ▷ Reenraizar a árvore em L[0]
4:    $Layers \leftarrow \text{BFS}(Tree)$  ▷ Obter camadas por profundidade
5:    $TopLayers \leftarrow \text{TOP}(Layers, Threshold)$  ▷ Selecionar camadas até o Threshold
6:    $\text{Soclade} \leftarrow \text{FLATTEN}(TopLayers)$  ▷ Achatar as camadas em uma lista única
7:    $\text{PRUNE}(Tree, \text{Soclade})$  ▷ Podar a árvore mantendo os nós em Soclade
8:   retorna  $\text{Soclade}$ 
9: fim função

```

Algoritmo 4 – SM4

```

1: função SM4( $Tree, Target, Threshold$ )
2:    $(Leaves, DM) \leftarrow \text{CALCDISTMATRIX}(Tree)$  ▷ Calcular a matriz de distâncias
3:    $Sorted \leftarrow \text{CALCCOPHENETIC}(Tree, Target)$  ▷ Lista ordenada de (Folha, Distância)
4:    $SCophenetic \leftarrow \emptyset$ 
5:   para todo  $(Leaf, d) \in Sorted$  faça
6:     se  $d \leq Threshold$  então
7:        $SCophenetic \leftarrow SCophenetic \cup \{Leaf\}$ 
8:     senão
9:       break ▷ Parar se a distância exceder o Threshold
10:   fim se
11:   fim para
12:   retorna  $SCophenetic$ 
13: fim função

```

Algoritmo 5 – $CCC = C_m + C_p$

```

1: função CALCULACM(df, bloco, cats)
2:   card  $\leftarrow \prod_{v \in \text{bloco}} (|\text{cats}[v]|) - 1$  ▷ Produto das cardinalidades menos 1
3:   Cm  $\leftarrow \text{card} \times \log_2(|df| + 1)$  ▷ Cálculo de  $C_m$ 
4:   retorna Cm
5: fim função
6: função CALCULACP(df, bloco, cats)
7:   ent  $\leftarrow \text{CalcularEntropia}(\text{df}, \text{bloco}, \text{cats})$  ▷ Entropia (base 2) do bloco
8:   Cp  $\leftarrow |df| \times \text{ent}$  ▷ Cálculo de  $C_p$ 
9:   retorna Cp
10: fim função
11: função AVALIAPARTICOES(df, variaveis)
12:   cats  $\leftarrow \text{ObterCategorias}(\text{df}, \text{variaveis})$  ▷ Extrair categorias únicas para cada variável
13:   partes  $\leftarrow \text{TodasParticoes}(\text{variaveis})$  ▷ Gerar todas as partições possíveis
14:   resultados  $\leftarrow []$  ▷ Inicializar lista de resultados
15:   para todo particao in partes faça
16:     CmTotal  $\leftarrow 0$ , CpTotal  $\leftarrow 0$ 
17:     para todo bloco in particao faça
18:       Cm  $\leftarrow \text{CALCULACM}(\text{df}, \text{bloco}, \text{cats})$ 
19:       Cp  $\leftarrow \text{CALCULACP}(\text{df}, \text{bloco}, \text{cats})$ 
20:       CmTotal  $\leftarrow \text{CmTotal} + \text{Cm}$ 
21:       CpTotal  $\leftarrow \text{CpTotal} + \text{Cp}$ 
22:     fim para
23:     CCC  $\leftarrow \text{CmTotal} + \text{CpTotal}$  ▷ Integração:  $CCC = C_m + C_p$ 
24:     resultados.add((particao, CmTotal, CpTotal, CCC))
25:   fim para
26:   Ordenar(resultados, chave = CCC) ▷ Ordenar resultados por CCC (crescente)
27:   retorna resultados
28: fim função

```

NOMENCLATURA

Tabela 18 – Descrição das variáveis da Fundação ABC

Variável	Descrição	Variável	Descrição
PRES.MED	Pressão Média (mb)	PRES.MIN	Pressão Mínima (mb)
PRES.MAX	Pressão Máxima (mb)	T.MED	Temperatura Média (°C)
T.MIN	Temperatura Mínima (°C)	T.MAX	Temperatura Máxima (°C)
TSOL.MED	Temperatura do Solo Média (°C)	RAD	Radiação ($\text{w.m}^{-2}.\text{s}^{-1}$)
UR.MED	Umidade Relativa do Ar (%)	VT.MED	Vento Médio (m s^{-1})
DIRVT	Direção do Vento (graus)	VT.MAX	Vento Máximo (m s^{-1})
PREC	Precipitação (mm)	DPM	Duração do Período de Molhamento Foliar (h)
TMOL	Temperatura do Molhamento Foliar (°C)	NHTmed < 12	Nº Horas T. Média < 12 (°C)
NHTmed > 24	Nº Horas T. Média > 24 (°C)	NHTmin < 8	Nº Horas T. Mínima < 8 (°C)
NHTmin > 20	Nº Horas T. Mínima > 20 (°C)	NHTmax < 24	Nº Horas T. Máx. < 24 (°C)
NHTmax > 32	Nº Horas T. Máx. > 32 (°C)	NHUR < 50	Nº Horas UR Média < 50 (%)
NHUR > 70	Nº Horas UR Média > 70 (%)	NHPREC = 0.0	Nº Horas c/ Precipitação = 0 (mm)
NHRAD < 400	Nº Horas Radiação Solar < 400 ($\text{w.m}^{-2}.\text{s}^{-1}$)	NHRAD > 800	Nº Horas Radiação Solar > 800 ($\text{w.m}^{-2}.\text{s}^{-1}$)
NHP > 1000	Nº Horas Pressão Atmosférica > 1000 (mb)	NHVT < 3	Nº Horas Vento Médio < 3 (m s^{-1})
NHVT > 7	Nº Horas Vento Médio > 7 (m s^{-1})	NHDPM=0	Nº Horas Duração do Molhamento Foliar = 0 (h)
NHTMOL < 14	Nº Horas T. do Molhamento Foliar < 14 (°C)	NHTMOL > 24	Nº Horas T. do Molhamento Foliar > 24 (°C)
PREC.INT.MED	Intensidade Média da precipitação (mm h^{-1})	ea	Pressão Parcial de Vapor (kPa)
to	Temperatura do Orvalho (°C)	THI	Índice de Temperatura e Umidade
NH.THI>72	Nº de Índice de Temperatura e Umidade > 72	TPT.NOT	Temperatura Noturna (°C)
EI30	Índice de erosividade das chuvas (MJ ha mm)	TSOL.MIN	Temperatura do Solo Mínimo (°C)
TSOL.MAX	Temperatura do Solo Máximo (°C)	VT2.MED	Vento (2) Médio (m s^{-1})
VT2.MAX	Vento (2) Máximo (m s^{-1})	RFA	Radiação Fotossinteticamente Ativa ($\text{MJ.m}^{-2}.\text{h}$)
IF.TPT.MI	Índice Fav. de Temperatura Milho (0 a 1)	IF.TPT.SO	Índice Fav. de Temperatura Soja (0 a 1)
IF.TPT.FE	Índice Fav. de Temperatura Feijão (0 a 1)	IF.TPT.TR	Índice Fav. de Temperatura Trigo (0 a 1)
IF.RAD.MI	Índice Fav. de Radiação Milho (0 a 1)	IF.RAD.SO	Índice Fav. de Radiação Soja (0 a 1)
IF.RAD.FE	Índice Fav. de Radiação Feijão (0 a 1)	IF.RAD.TR	Índice Fav. de Radiação Trigo (0 a 1)
IF.VT.MI	Índice Fav. de Vento Milho (0 a 1)	IF.VT.SO	Índice Fav. de Vento Soja (0 a 1)
IF.VT.FE	Índice Fav. de Vento Feijão (0 a 1)	IF.VT.TR	Índice Fav. de Vento Trigo (0 a 1)
IF.POL.MI	Índice Fav. da Puccinia polysora (milho) (0 a 1)	IF.FER.SO	Índice Fav. da Ferrugem da Soja (0 a 100)
IF.OID.SO	Índice Fav. de Oídio em Soja (0 a 100)	IF.ANT.FE	Índice Fav. de Antracnose em Feijão (0 a 100)
IF.ANG.FE	Índice Fav. Mancha Angular em Feijão (0 a 100)	IF.OID.TR	Índice Fav. Oídio em Trigo (0 a 1)
IF.FER.TR	Índice Fav. Ferrugem em Trigo (0 a 1)	IF.MAN.TR	Índice Fav. Mancha em Trigo (0 a 1)
IF.SEP.TR	Índice Fav. Septoria em Trigo (0 a 1)	IF.HEL.TR	Índice Fav. Helmintosporiose em Trigo (0 a 1)

Continua na próxima página...

Tabela 18 – Continuação

Variável	Descrição	Variável	Descrição
IF.GIB.TR	Índice Fav. Giberela em Trigo (0 a 1)	IF.BRU.TR	Índice Fav. Brusone em Trigo (0 a 1)
DATA.J	Data	dr	dr
es(Tmin)	Pressão Saturação de Vapor T. Mín. (kPa)	es(Tmax)	Pressão Saturação de Vapor T. Máx. (kPa)
es	Pressão Saturação de Vapor (kPa)	Delta	Declividade da Curva de Pressão de Vapor ($^{\circ}\text{C}^{-1}$)
Declinação do Sol	Declinação do Sol	Ângulo horário nascer Sol	Ângulo horário nascer Sol
RAD.TA	Radiação no Topo da Atmosfera (MJ m^{-2})	Água precipitável	Água precipitável
RAD.CC	Radiação Solar com Céu Claro (MJ m^{-2})	FOTOP	Fotoperíodo (h)
RN.SW	Radiação Solar de Onda Curta (MJ m^{-2})	RN.LW	Radiação Solar de Onda Longa (MJ m^{-2})
URMAX	Umidade Relativa Máxima (%)	URMIN	Umidade Relativa Mínima (%)
ea2	Método alternativo p/ Pressão de Vapor	Água precipitável2	Método alternativo p/ Água precipitável
ETP.PM	Evapotranspiração Potencial (mm)	ETP.PM2	Evapotranspiração Potencial (mm)
T.ORV	Temperatura do Orvalho ($^{\circ}\text{C}$)	ITU	Índice de Temperatura e Umidade
PREC.INT	Precipitação Instantânea (mm)	ND.VT<5	Nº de Dias c/ Vento Médio < 5 (m s^{-1})
ND.VT>5	Nº de Dias c/ Vento Médio > 5 (m s^{-1})	VT2.TOT	Vento Total (Km h^{-1})
ND.IF.TPT.MI>0.5	Nº Dias c/ Índice Fav. T. Milho > 0.5	ND.IF.TPT.SO>0.6	Nº Dias c/ Índice Fav. T. Soja > 0.6
ND.IF.TPT.FE>0.8	Nº Dias c/ Índice Fav. T. Feijão > 0.8	ND.IF.TPT.TR>0.5	Nº Dias c/ Índice Fav. T. Trigo > 0.5
ND.IF.RAD.MI>0.6	Nº Dias c/ Índice Fav. Rad. Milho > 0.6	ND.IF.RAD.SO>0.7	Nº Dias c/ Índice Fav. Rad. Soja > 0.7
ND.IF.RAD.FE>0.7	Nº Dias c/ Índice Fav. Rad. Feijão > 0.7	ND.IF.RAD.TR>0.6	Nº Dias c/ Índice Fav. Rad. Trigo > 0.6
ND.IF.VT.MI>0.8	Nº Dias c/ Índice Fav. Vento Milho > 0.8	ND.IF.VT.SO>0.8	Nº Dias c/ Índice Fav. Vento Soja > 0.8
ND.IF.VT.FE>0.8	Nº Dias c/ Índice Fav. Vento Feijão > 0.8	ND.IF.VT.TR>0.8	Nº Dias c/ Índice Fav. Vento Trigo > 0.8
ND.IF.POL.MI>60	Nº Dias c/ Índice Fav. Puccinia (milho) > 0.6	ND.IF.FER.SO>80	Nº Dias c/ Índice Fav. Ferrugem Soja > 80
ND.IF.OID.SO>80	Nº Dias c/ Índice Fav. Oídio Soja > 80	ND.IF.ANT.FE>60	Nº Dias c/ Índice Fav. Antracnose Feijão > 60
ND.IF.ANG.FE>60	Nº Dias c/ Índice Fav. Mancha Angular Feijão > 60	RAD.EFIC	Radiação solar disponível em superfície (%)
ND.ITU>72	Nº Dias c/ Índice T. e Umidade > 72	GD	Graus dias ($^{\circ}\text{C}\cdot\text{dias}$)
GDA	Graus dias Acumulados ($^{\circ}\text{C}\cdot\text{dias}$)	NDTmed < 10	Nº Dias T. Média < 10 ($^{\circ}\text{C}$)
NDTmed > 24	Nº Dias T. Média > 24 ($^{\circ}\text{C}$)	NDTmin < 8	Nº Dias T. Mínima < 8 ($^{\circ}\text{C}$)
NDTmin > 18	Nº Dias T. Mínima > 18 ($^{\circ}\text{C}$)	NDTmax < 24	Nº Dias T. Máx. < 24 ($^{\circ}\text{C}$)
NDTmax > 32	Nº Dias T. Máx. > 32 ($^{\circ}\text{C}$)	NDUR < 60	Nº Dias UR Média < 60 (%)
NDUR > 80	Nº Dias UR Média > 80 (%)	NDPREC = 0.0	Nº Dias c/ Precipitação = 0 (mm)
NDRAD < 6	Nº Dias c/ Radiação Solar < 6 ($\text{MJ}\cdot\text{m}^{-2}\cdot\text{h}$)	NDRAD > 20	Nº Dias c/ Radiação Solar > 20 ($\text{MJ}\cdot\text{m}^{-2}\cdot\text{h}$)
NDP > 1000	Nº Dias Pressão Atmosférica > 1000 (mb)	NDVT < 3	Nº Dias Vento Médio < 3 (mb)
NDVT > 7	Nº Dias Vento Médio > 7 (mb)	NDDPM=0	Nº Dias c/ Duração Molhamento Foliar = 0 (h)
NDDPM > 10	Nº Dias c/ Duração Molhamento Foliar > 10 (h)	NDTMOL < 14	Nº Dias T. Molhamento Foliar < 14 ($^{\circ}\text{C}$)
NDTMOL > 24	Nº Dias T. Molhamento Foliar > 24 ($^{\circ}\text{C}$)	AMPLT	Amplitude Térmica ($^{\circ}\text{C}$)
NDAMPLIT > 12	Nº Dias c/ Amplitude Térmica > 12 ($^{\circ}\text{C}$)	PRESMED_HR_Soma	Soma Pressão Média Horária (mb)
PRESMIN_HR_Soma	Soma Pressão Mín. Horária (mb)	PRESMAX_HR_Soma	Soma Pressão Máx. Horária (mb)
TMED_HR_Soma	Soma T. Média Horária ($^{\circ}\text{C}$)	TMIN_HR_Soma	Soma T. Mín. Horária ($^{\circ}\text{C}$)
TMAX_HR_Soma	Soma T. Máx. Horária ($^{\circ}\text{C}$)	TSOLO_HR_Soma	Soma T. Solo Horária ($^{\circ}\text{C}$)
RADHR_Soma	Soma Radiação Horária ($\text{MJ}\cdot\text{m}^{-2}\cdot\text{h}$)	URMED_HR_Soma	Soma UR Horária (%)
VTMED_HR_Soma	Soma Vento Médio Horário (m s^{-1})	DIRVT_HR_Soma	Soma Direção do Vento Horária (graus)
VTMAX_HR_Soma	Soma Vento Máx. Horário (m s^{-1})	PRECHR_Soma	Soma Precipitação Horária (mm)
DMPHR_Soma	Soma Duração Molhamento Foliar (h)	TMOL_HR_Soma	Soma Temperatura do Molhamento Foliar ($^{\circ}\text{C}$)

TESTE DE ASSIMETRIA E CURTOSE

Figura 29 – Teste de Assimetria e Curtose

