

Introdução

A seleção de atributos é especialmente relevante em aplicações agrícolas que combinam variáveis agrônômicas e dados hiperespectrais. Neste trabalho, o GAwLL (Genetic Algorithm with Linkage Learning) foi utilizado para identificar atributos importantes e relações de interação entre eles, visando reduzir a dimensionalidade sem comprometer o desempenho dos modelos, além de nos dar informações para a explicabilidade dos mesmos. [1,2].

Objetivo

Neste projeto, o GAwLL será utilizado para obter informações de importância e interação de variáveis em imagens espectrais em agricultura. Diferentes modelos de AM serão empregados, entre eles redes neurais artificiais, árvores de decisão, florestas aleatórias e K-vizinhos mais próximos.

Materiais e Métodos

Fundação ABC

3.675 × 54

Produtividade de soja (kg/ha) [4]
10 folds • métrica R²

Imagens hiperespectrais

1.935 × 1.933

Controle, lagarta e inseto [3]
5 folds • métrica: acurácia

Fluxo experimental



Modelos

MLP • Árvore de decisão • Floresta aleatória • KNN

GAwLL

População = 100 • 100 gerações • crossover = 0,8 • mutação = 0,3
Seleção por roleta + elitismo [5]

f(x) = 0,9 · m(x) + 0,1 · (1 - Σxi/N) (1)

Efeito da inversão do atributo g

δg(x) = f(x ⊕ 1g) - f(x) (2)

Efeito de g após inverter h

δg(x ⊕ 1h) = f(x ⊕ 1h ⊕ 1g) - f(x ⊕ 1h) (3)

Interação entre os atributos g e h

ωg,h(x) = |δg(x ⊕ 1h) - δg(x)| (4)

Importância do atributo g

ŵimp(g) = max x∈Y(g) |δg(x)| (5)

Intensidade da interação entre g e h

ŵint(g,h) = max x∈Y(g,h) ωg,h(x) (6)

Desenvolvimento

Os experimentos foram implementados em Python com Scikit-learn, Pandas, NumPy e Matplotlib. Cada modelo foi avaliado inicialmente com todos os atributos e, em seguida, com o subconjunto selecionado pelo GAwLL. Também foram estimadas a importância e a interação entre os atributos.

Resultados | Base Fundação ABC

Na Fundação ABC, a comparação utiliza R² médio em validação cruzada com 10 folds. A seleção aumentou o R² de três dos quatro modelos e reduziu o conjunto de 54 para, em média, 13 atributos.

Todos os atributos




Figura 1 — Desempenho com todos os atributos.

Após a seleção pelo GAwLL




Figura 2 — Desempenho com atributos selecionados.

Comparação do R² médio

Modelo	Antes	Depois	Variação
Floresta aleatória	0,58	→ 0,64	+0,06
KNN	0,25	→ 0,49	+0,24
Árvore de decisão	0,26	→ 0,25	-0,01
MLP	0,10	→ 0,45	+0,35

Atributos: 54 → 12–15 por modelo (média = 13; redução ≈ 76%)

O MLP e o KNN apresentaram os maiores ganhos de R².

Resultados | Imagens hiperespectrais

Na base hiperespectral, a comparação utiliza acurácia média em validação cruzada com 5 folds. As variações após a seleção foram pequenas, mesmo com a redução de 1.933 bandas para 871–947 atributos.

Todos os atributos




Figura 3 — Desempenho com todos atributos.

Após a seleção pelo GAwLL




Figura 4 — Desempenho com atributos selecionados.

Modelo	Antes	Depois	Variação
Floresta aleatória	0,46	→ 0,45	-0,01
KNN	0,41	→ 0,40	-0,01
Árvore de decisão	0,40	→ 0,42	+0,02
MLP	0,42	→ 0,44	+0,02

Atributos: 1.933 → KNN 871 | RF 900 | MLP 920 | DT 947 (redução de 51,0% a 54,9%)

Interação entre atributos

Os grafos mostram que atributos relevantes e padrões de interação dependem do modelo. A espessura das arestas representa a intensidade da interação estimada.

VIG - Interação Média: MLP




Figura 5 — Grafo de interação obtido para o MLP.

Conclusões

Na base Fundação ABC, os maiores ganhos ocorreram no MLP e no KNN; apenas a árvore de decisão apresentou pequena redução de R². Na base hiperespectral, as diferenças de acurácia foram discretas: dois modelos melhoraram e dois apresentaram leve queda. Assim, o GAwLL reduziu a dimensionalidade significativamente (~76% para base da Fundação ABC e ~52% para as Imagens Hiperespectrais) mantendo desempenho semelhante ou relativamente melhor em alguns casos, além de fornecer informações sobre importância e interação de atributos.

Referências

[1] TINÓS, R.; PRZEWOZNICZEK, M. W.; WHITLEY, D.; CHICANO, F. Genetic Algorithm with Linkage Learning. GECCO, 2023.
[2] TINÓS, R. et al. Learning Variable Importance and Interaction in Genetic Algorithms. Evolutionary Computation, submetido, 2025.
[3] CORREA, D. V. et al. Aprendizagem de máquina para identificação de plantas de soja sob ataque de insetos usando dados hiperespectrais. Colloquium Exactarum, 14(1), 2022.
[4] RUELAS, J. L. J. Análise filogenética e modelagem estrutural para otimização da produção agrícola. USP, 2025.
[5] EIBEN, A. E.; SMITH, J. E. Introduction to Evolutionary Computing. Springer, 2003.

Agradecimentos

Ao Programa Institucional de Bolsas de Iniciação Científica (PIBIC), à Universidade de São Paulo e ao orientador pelo apoio ao desenvolvimento deste trabalho.