

**Departamento de Computação e Matemática
Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto
(FFCLRP)
Universidade de São Paulo (USP)**

Relatório Parcial – Programa Institucional de Bolsas de Iniciação
Científica (PIBIC)
Código do Projeto – 2025-1051
Vigência: 01/09/2025 a 31/08/2026

**Algoritmos Genéticos para Estimação de Importância e
Interação de Atributos na Classificação de Imagens
Espectrais em Agricultura**

**Aluno: Daniel Natan dos Santos Brito
Orientador: Renato Tinós**

Ribeirão Preto
2026

Sumário

1 Projeto.....	3
1.1 Resumo.....	3
1.2 Justificativa.....	3
1.3 Objetivos.....	4
2 Revisão da literatura.....	4
2.1 Aprendizado de Máquina.....	4
2.2 Modelos de Aprendizado.....	5
2.2.1 Rede neural artificial.....	5
2.2.2 Árvore de decisão.....	5
2.2.3 Floresta aleatória.....	5
2.2.4 K-vizinhos mais próximos.....	6
2.3 Algoritmos Genéticos.....	6
2.3.1 GAWLL.....	7
3 Metodologia.....	8
3.1 Base de dados.....	8
3.2 Código.....	8
3.3 Função de Fitness e Hiperparâmetros.....	8
4 Resultados.....	9
4.1 Treinamento dos modelos com todos os atributos.....	10
4.2 Importância das variáveis por algoritmos do Scikit-learn.....	11
4.3 Importância das variáveis pelo algoritmo genético.....	13
4.4 Treinamento dos modelos com os atributos selecionados pelo algoritmo genético.....	15
5 Referências.....	16

1 Projeto

1.1 Resumo

Recentemente, o algoritmo genético com linkage learning (*genetic algorithm with linkage learning* - GAwLL) foi proposto. O GAwLL descobre um grafo de interações entre variáveis de decisão como um efeito colateral da otimização realizada por um algoritmo genético. Uma aplicação interessante do GAwLL é no problema de seleção de atributos em aprendizado de máquina (AM). Neste caso, o GAwLL gera informações sobre a importância e interação de atributos, que são importantes para a explicabilidade de modelos de AM e para o entendimento, por parte dos especialistas, sobre o problema investigado. Neste projeto, o GAwLL será aplicado para estimar a importância e interação de atributos no problema de classificação de imagens espectrais em Agricultura. Em particular, estamos interessados na classificação de plantas em lavouras de soja. Diferentes modelos de AM, em especial, redes neurais artificiais, árvores de decisão e florestas aleatórias, serão aplicados.

1.2 Justificativa

Selecionar atributos relevantes para tarefas de classificação e regressão é uma importante tarefa em aprendizado de máquina (AM). O método mais simples para selecionar um conjunto de atributos é empregar a busca exaustiva, no qual um classificador para cada conjunto de atributos é testado e o desempenho obtido é comparado. No entanto, a busca exaustiva é computacionalmente inviável, pois implica no teste de um número exponencial de combinações de atributos. Com isso, quando o número de atributos é grande, outros métodos têm sido empregados para selecioná-los.

Um deles é o algoritmo genético com linkage learning [TINÓS et al., 2023], que descobre um grafo de interações entre as variáveis como um efeito colateral da otimização realizada por um algoritmo genético (AG). Uma versão mais recente do algoritmo permite ainda a estimação da importância das variáveis [TINÓS et al., 2025]. Descobrir a importância de atributos e como eles interagem, dado uma base

de dados, é importante para a explicabilidade dos modelos de AM e para o entendimento de propriedades do problema investigado.

1.3 Objetivos

Neste projeto, o GAWLL será utilizado para obter informações de importância e interação de variáveis em imagens espectrais em agricultura [CORREA et al., 2022]. Em particular, estamos interessados no problema de classificação de plantas em lavouras de soja. Diferentes modelos de AM serão empregados, entre eles redes neurais artificiais, árvores de decisão, florestas aleatórias e K-vizinhos mais próximos.

2 Revisão da literatura

No primeiro semestre da realização do projeto a primeira atividade foi uma revisão da literatura e dos conceitos importantes para o desenvolvimento da pesquisa, como aprendizado de máquina e algoritmos genéticos. Para isso, foram feitos diversos experimentos utilizando modelos de aprendizado de máquina e testes com algoritmos para estimar a importância dos atributos utilizando a biblioteca Scikit-learn em Python. Também foi feito um estudo sobre o algoritmo GAWLL e uma implementação de um algoritmo genético, também em Python, aplicando os conceitos vistos na literatura.

2.1 Aprendizado de Máquina

Aprendizado de máquina é um subcampo da inteligência artificial, que, de acordo com [GÉRON, 2019], é a ciência da programação de computadores para que eles possam aprender com os dados, ou seja, tem como base o estudo de algoritmos que podem, a partir de um conjunto de informações agrupadas em uma base de dados, identificar padrões e a partir disso prever resultados futuros. Existem diversos modelos de aprendizado de máquina, cada um com seu método de analisar as informações e identificar os padrões, com diferentes níveis de complexidade. Além disso, esses algoritmos estão divididos em diferentes formas

de aprendizado, entre elas supervisionado, não supervisionado, semi supervisionado e por reforço.

2.2 Modelos de Aprendizado

2.2.1 Rede neural artificial

Modelo que tem como inspiração o funcionamento do cérebro humano, utilizando o conceito de neurônios artificiais. É composta por uma camada de entrada, que recebe os dados brutos, as camadas ocultas, que fazem diversas operações com esses dados a partir de pesos entre as ligações dos neurônios e funções de ativação, essas camadas podem ou não estar presentes, e por fim, a camada de saída, onde temos o resultado da predição ou classificação. Para o treinamento do modelo é utilizado o algoritmo de *backpropagation* (retropropagação) no qual a partir do erro da saída, ele ajusta os pesos e os vieses.

2.2.2 Árvore de decisão

Modelo que utiliza do conceito da estrutura de dados árvore, no qual em cada nó interno representa uma condição que será aplicada a um atributo específico dos dados. Ao longo de várias decisões os dados são divididos cada vez mais até que um nó folha é alcançado, que é responsável por fornecer a classificação ou a predição. A escolha do atributo que será utilizado em cada divisão depende de métricas de impureza, como por exemplo o índice Gini ou a entropia, que mede a desordem dos dados em um nó.

2.2.3 Floresta aleatória

Modelo baseado no conceito de *ensemble learning*, que combina diversas árvores de decisão para melhorar a capacidade preditiva. Nesse modelo diversas árvores aleatórias são treinadas individualmente a partir de subconjuntos de dados. A previsão final é obtida por meio da agregação dos resultados de cada árvore de decisão. Na classificação é utilizado a votação majoritária, ou seja, a classificação

que mais aparece se torna a classificação final. Na regressão, calcula-se a média das predições.

2.2.4 K-vizinhos mais próximos

Modelo que realiza predições com base na similaridade entre os dados. O KNN não tem uma fase de treinamento, ele apenas armazena os dados e realiza os cálculos das distâncias no momento da predição.

Para classificar um novo dado, o algoritmo calcula a distância entre essa nova instância e todas as amostras do conjunto de treinamento, utilizando não só a distância euclidiana mas também podendo utilizar outras métricas como a Manhattan ou Minkowski. A partir disso, seleciona os K vizinhos mais próximos dessa nova instância e determina como sendo a classe predominante entre eles.

2.3 Algoritmos Genéticos

Algoritmos genéticos é uma abordagem que se baseia na teoria da evolução para resolver problemas de otimização [EIBEN; SMITH, 2003]. Primeiramente temos a criação dos indivíduos, que chamamos de cromossomos, no qual cada um representa uma possível solução para o problema. Aqui, utilizamos os algoritmos genéticos para o problema da seleção de atributos em AM, no qual os indivíduos representam subconjuntos dos atributos que serão utilizados pelo modelo de AM. Geralmente esses indivíduos são representados como um vetor de bits, no qual 1 na n-ésima posição representa que o n-ésimo atributo está presente na solução, e 0 representa que o atributo não está presente na solução.

A partir disso, utilizamos uma função de *fitness* para comparar a qualidade de cada solução. O objetivo pode ser maximizar ou minimizar essa função, dependendo do problema no qual esteja trabalhando. Para alcançar as soluções mais promissoras existem diversas técnicas, como a reprodução, crossover e mutação, que visa gerar variabilidade no conjunto dos indivíduos.

2.3.1 GAwLL

O Algoritmo Genético com Linkage Learning (*Genetic Algorithm with Linkage Learning* - GAwLL) descobre um grafo de interações ponderado como efeito da otimização realizada por um AG. Ou seja, o GAwLL obtém informações sobre a interação entre as variáveis durante a execução do AG, sem necessitar de avaliações adicionais.

Seja $\mathbf{x}$ um vetor binário de tamanho N representando uma solução candidata de um problema com avaliação $f(\mathbf{x})$. A partir disso, o GAwLL gera outros 3 indivíduos, um invertendo o g -ésimo bit do vetor $\mathbf{x}$, outro invertendo o h -ésimo bit, e por último invertendo o g -ésimo e o h -ésimo bit. Com isso, conseguimos obter as seguintes diferenças:

$$\delta_g(\mathbf{x}) = f(\mathbf{x} \oplus \mathbf{1}_g) - f(\mathbf{x}) \quad (1)$$

$$\delta_h(\mathbf{x} \oplus \mathbf{1}_h) = f(\mathbf{x} \oplus \mathbf{1}_h \oplus \mathbf{1}_g) - f(\mathbf{x} \oplus \mathbf{1}_h) \quad (2)$$

$$\omega_{g,h}(\mathbf{x}) = |\delta_g(\mathbf{x} \oplus \mathbf{1}_h) - \delta_g(\mathbf{x})|. \quad (3)$$

no qual o símbolo $\oplus$ representa a operação XOR, $f(\mathbf{x})$ representa o valor de *fitness* de $\mathbf{x}$, $f(\mathbf{x} \oplus \mathbf{1}_g)$ o valor de *fitness* de $\mathbf{x}$ invertendo o g -ésimo bit, $f(\mathbf{x} \oplus \mathbf{1}_h)$ o valor de *fitness* de $\mathbf{x}$ invertendo o h -ésimo bit e $f(\mathbf{x} \oplus \mathbf{1}_h \oplus \mathbf{1}_g)$ a função de *fitness* de $\mathbf{x}$ invertendo tanto o h -ésimo bit quanto o g -ésimo bit. Em [TINÓS et al., 2023], demonstra-se que as variáveis x_g e x_h interagem se $\omega_{g,h} > 0$.

Além disso, em [TINÓS et al, 2025], demonstra-se que a importância da variável x_g é dada por:

$$\hat{v}_{imp}(g) = \max_{\mathbf{x} \in \Upsilon(g)} |\delta_g(\mathbf{x})| \quad (4)$$

no qual $\Upsilon(g) \in B^N$ é um subconjunto das soluções visitadas pelo espaço de busca para computar $\hat{v}_{imp}(g)$.

3 Metodologia

3.1 Base de dados

Neste trabalho foi utilizada uma base de dados utilizada em [RUELAS, 2025], disponibilizada pela Fundação ABC que descreve diversos fatores físicos, químicos e biológicos na produção de soja. O atributo alvo para a realização do trabalho foi a produtividade de soja em kg por hectare. A base possui 3675 instâncias com 54 atributos.

3.2 Código

Para a realização deste trabalho foram realizados quatro códigos principais em Python, utilizando as bibliotecas Scikit-learn, Pandas, Numpy e Matplotlib. Os códigos têm por finalidade, respectivamente, calcular a performance dos modelos utilizando todas as variáveis, encontrar as variáveis mais importantes utilizando algoritmos do próprio Scikit-learn, implementação de um algoritmo genético para encontrar as variáveis mais importantes e novo treinamento dos modelos mas com o grupo de variáveis mais importantes.

3.3 Função de Fitness e Hiperparâmetros

Nos modelos de aprendizado de máquina foram utilizados os hiperparâmetros padrões da biblioteca Scikit-learn. No algoritmo genético foram utilizados os seguintes parâmetros: população com 100 indivíduos, 100 gerações, taxa de crossover de 0.8, taxa de mutação de 0.3, 10 indivíduos para o elitismo e a seguinte função de *fitness*:

$$f(\mathbf{x}) = 0,9 \cdot acc(\mathbf{x}) + 0,1 \cdot (1 - \sum_{i=1}^N \mathbf{x}_i / N) \quad (5)$$

no qual N se refere ao tamanho do cromossomo (quantidade de atributos) e $acc(\mathbf{x})$ se refere a acurácia.

4 Resultados

Os testes foram feitos utilizando o ambiente Jupyter Notebook para a realização dos códigos, no qual foi feito um tratamento inicial na base de dados e posteriormente os modelos foram treinados e avaliados utilizando a validação cruzada com 5 *folds*. Foram utilizados quatro modelos da biblioteca Scikit-Learn, o MLP (*Multi Layer Perceptron*), que se refere a rede neural, Árvore de decisão, K vizinhos mais próximos e Floresta Aleatória. A métrica utilizada para os resultados foi a acurácia dos modelos. A Figura 1 compara o resultado da acurácia média entre cada modelo treinado.

A importância dos atributos foi realizada de duas formas, primeiro foi utilizado algoritmos já pertencentes a cada modelo da biblioteca Scikit-learn, que retornam uma lista ordenada desses algoritmos. A Figura 2 mostra os 10 atributos mais importantes para o modelo MLP, assim sucessivamente, a Figura 3 mostra os 10 mais importantes para o modelo Decision Tree, a Figura 4 mostra os 10 mais importantes para o modelo Random Forest e a Figura 5 os 10 mais importantes para o modelo K-vizinhos mais próximos.

Após isso, foi implementado um algoritmo genético em Python que foi aplicado em cada modelo, no qual cada um gerou uma lista dos atributos mais importantes. Por fim, conforme a Figura 6, foi realizado novamente a avaliação dos modelos, também utilizando validação cruzada com 5 *folds* e tendo a acurácia como métrica, mas apenas com as variáveis selecionadas pelo algoritmo genético.

4.1 Treinamento dos modelos com todos os atributos




Figura 1: Gráfico representando a acurácia média, utilizando 5 folds no cross-validation, obtida por cada modelo no treinamento com todos os atributos.

4.2 Importância das variáveis por algoritmos do Scikit-learn




Figura 2: Os 10 atributos mais importantes para o modelo MLP




Figura 3: Os 10 atributos mais importantes para o modelo Decision Tree




Figura 4: Os 10 atributos mais importantes para o modelo Random Forest




Figura 5: Os 10 atributos mais importantes para o modelo K-vizinhos mais próximos

4.3 Importância das variáveis pelo algoritmo genético

A partir do algoritmo genético implementado em Python foi possível identificar as variáveis mais importantes de cada modelo.

MLP (13 atributos):

- UF
- ND.TMIN < 10 [sum]
- Altitude Média [classe]
- Genótipos Propósito
- Solo Textura
- Solo Grupo
- Genótipos
- Umidade Relativa Mínima [soma]
- Umidade Relativa [soma]
- Inseticida Planejado [aplicações]
- Talhão Latitude [grau decimal]
- Colheita [data]_mes
- Colheita [data]_dia

Decision Tree (14 atributos):

- ND.TMIN < 10 [sum]
- Colheita [data]
- Genótipos Propósito
- Talhão
- Genótipos
- Evapotranspiração Potencial PM [soma]
- Herbicida Planejado [aplicações]
- ND.UR < 60 [sum]
- Talhão Latitude [grau decimal]
- Talhão Longitude [grau decimal]
- Colheita [decendio]
- Semeadura [decendio]
- ND.PREC = 0.0 [sum]
- Colheita [data]_mes

Random Forest (12 atributos):

- Genótipos Propósito
- Solo Textura
- Genótipos
- Fungicida Planejado [aplicações]
- Herbicida Planejado [aplicações]
- Inseticida Planejado [aplicações]
- Talhão Latitude [grau decimal]
- Talhão Longitude [grau decimal]
- Colheita [decendio]
- ND.RAD < 10 [sum]
- Semeadura [decendio]
- ND.TMAX > 30 [sum]

KNN (15 Atributos):

- Genótipos Propósito
- Tipo Safra
- Altitude Máxima [m]
- NH.UR > 90 [sum]
- Fungicida Planejado [aplicações]
- Herbicida Planejado [aplicações]
- Inseticida Planejado [aplicações]
- ND.UR > 80 [sum]
- ND.UR > 90 [sum]
- Talhão Latitude [grau decimal]
- Talhão Longitude [grau decimal]
- Semeadura [decendio]
- ND.TMAX > 30 [sum]
- NH.RAD > 1000 [sum]
- Colheita [data]_mes

4.4 Treinamento dos modelos com os atributos selecionados pelo algoritmo genético




Figura 6: Gráfico representando a acurácia média, utilizando 5 folds no cross-validation, obtida por cada modelo no treinamento com os atributos selecionados por cada modelo pelo algoritmo genético.

Analisando os resultados obtidos, comparando as figuras 1 e 6, podemos observar que o desempenho dos modelos aumentaram significativamente após o treinamento com os atributos selecionados. Além disso, o tempo necessário para o treinamento diminuiu consideravelmente, dado que antes eram utilizados 54 atributos e após a seleção foram utilizados em média 13 atributos (redução de aproximadamente 76% na quantidade de atributos).

O aumento na acurácia se dá por conta de que existem muitos atributos que não são significativos para a tarefa de predição, com isso, ao utilizar todos os atributos no treinamento os modelos podem ser induzidos a erros. Ao utilizar a técnica de seleção de atributos, encontramos uma possível solução apenas com os atributos realmente significativos para a predição.

5 Referências

EIBEN, A. E.; SMITH, J. E. (2003) *"Introduction to evolutionary computing"*. Berlin: Springer

GÉRON, A. (2019). "Mãos à obra: aprendizado de máquina com Scikit-Learn & TensorFlow", Alta Books.

RUELAS, J. L. J. (2025). "Análise filogenética e modelagem estrutural para otimização da produção agrícola". Monografia (Exame de Qualificação – Doutorado em Ciências: Ciências de Computação e Matemática Computacional) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2025.

TINÓS, R.; PRZEWOZNICZEK, M. W.; WHITLEY, D. & CHICANO, F. (2023). "Genetic Algorithm with Linkage Learning". In the Proc. of the 2023 Genetic and Evolutionary Computation Conference (GECCO'23), Lisboa, Portugal, p. 981-989.

TINÓS, R.; CHICANO, F.; PRZEWOZNICZEK, M. W. & WHITLEY, D. & (2025). "Learning Variable Importance and Interaction in Genetic Algorithms". Submitted to Evolutionary Computation.

CORREA, D. V.; RAMOS, A. P. M.; OSCO, L. P. & JORGE, L. A. C. (2022). "Aprendizagem de máquina para identificação de plantas de soja sob ataque de insetos usando dados hiperespectrais", Colloquium Exactarum, 14(1): 146-153.