

Algoritmos Genéticos para Estimação de Importância e Interação de Atributos na predição de produtividade de lavouras de soja

Daniel Natan dos Santos Brito

Orientador: Prof. Renato Tinós

Departamento de Computação e Matemática da Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto/Universidade de São Paulo

danielnatanbrito@usp.br

Objetivos

O projeto tem como objetivo aplicar o algoritmo genético com linkage learning (GAwLL) [1] para estimar a importância e a interação de atributos utilizados por diferentes modelos de aprendizado de máquina na predição da produtividade de lavouras de soja, tema já abordado com dados climáticos e índices de vegetação [2]. Além de comparar o desempenho preditivo de *multilayer perceptrons* (MLP), árvores de decisão, florestas aleatórias e K-vizinhos mais próximos (KNN), busca-se identificar, a partir do GAwLL, quais variáveis agronômicas mais contribuem para a predição e como elas se relacionam entre si, informação relevante tanto para a explicabilidade dos modelos quanto para o entendimento do problema agrícola em si.

Métodos e Procedimentos

O GAwLL parte de um algoritmo genético (AG) padrão, no qual cada indivíduo $\mathbf{x}$ é um vetor binário de tamanho N que indica quais dos N atributos disponíveis compõem a solução, avaliada por uma função de fitness $f(\mathbf{x})$. A cada avaliação, o GAwLL gera três indivíduos derivados de $\mathbf{x}$: um com o g -ésimo bit invertido, outro com o h -ésimo bit invertido, e um terceiro com ambos invertidos simultaneamente. A partir das diferenças de fitness entre essas variações, calculam-se:

$$\delta_g(\mathbf{x}) = f(\mathbf{x} \oplus I_g) - f(\mathbf{x}) \quad (1)$$

$$\delta_h(\mathbf{x} \oplus I_h) = f(\mathbf{x} \oplus I_h \oplus I_g) - f(\mathbf{x} \oplus I_h) \quad (2)$$

$$\omega_{g,h}(\mathbf{x}) = |\delta_g(\mathbf{x} \oplus I_h) - \delta_g(\mathbf{x})| \quad (3)$$

em que $\oplus$ representa a operação XOR e $\mathbf{1}_g$ é um vetor binário com bit 1 apenas na g -ésima posição. Duas variáveis x_g e x_h interagem quando $\omega_{g,h}(\mathbf{x}) > 0$. A importância de uma variável g , por sua vez, é dada pelo maior valor absoluto de δ_g observado entre as soluções $\mathbf{x}$ visitadas pelo espaço de busca $Y(g)$:

$$\hat{v}_{imp}(g) = \max |\delta_g(\mathbf{x})|, \mathbf{x} \in Y(g) \quad (4)$$

Além disso, a interação entre as variáveis x_g e x_h é dada pelo maior valor de $\omega_{g,h}(\mathbf{x})$:

$$\hat{v}_{int}(g, h) = \max \omega_{g,h}(\mathbf{x}), \mathbf{x} \in Y(g, h) \quad (5)$$

O ponto central do GAwLL é que essas informações de importância e interação são obtidas como subproduto da própria otimização do AG, sem exigir avaliações adicionais de fitness além das já realizadas na busca. Para isso, foi utilizada uma implementação em Python do GAwLL que estende seu uso original, que era limitado ao KNN, para múltiplos modelos de aprendizado de máquina [3].

Para os experimentos, foi utilizada uma base de dados da Fundação ABC com 3.675 instâncias e 54 atributos físicos, químicos, biológicos e de manejo relacionados à lavoura de soja, tendo a produtividade (kg/hectare) como alvo. Os quatro modelos (MLP, Árvore de Decisão, Floresta Aleatória e KNN) foram treinados com os hiperparâmetros padrão do Scikit-learn e avaliados por validação cruzada com 5 folds, usando acurácia como métrica. O algoritmo genético foi configurado com população de 100 indivíduos, 100 gerações, taxa de crossover de 0,8, taxa de mutação de 0,3, seleção por roleta e elitismo, com a seguinte função de fitness:

$$f(\mathbf{x}) = 0,9 \cdot \text{acc}(\mathbf{x}) + 0,1 \cdot \left(1 - \sum_{i=1}^n x_i / N\right) \quad (6)$$

que combina a acurácia (acc) do modelo com os atributos dados por $\mathbf{x}$ e com um termo de penalização proporcional ao número de atributos selecionados, incentivando soluções com alta acurácia e poucos atributos.

Resultados




Figura 1: Acurácia média (5 folds) de cada modelo com todos os 54 atributos.




Figura 2: Acurácia média (5 folds) de cada modelo com os atributos selecionados pelo GAWLL.

As figuras 1 e 2 mostram o resultado de acurácia do treinamento com os 54 atributos originais, a Floresta Aleatória obteve a melhor acurácia média ($\approx 0,56$), seguida por KNN ($\approx 0,23$), Árvore de Decisão ($\approx 0,20$) e MLP ($\approx 0,11$). Todos os modelos melhoraram após a seleção pelo GAWLL, com destaque para Floresta Aleatória ($0,56 \rightarrow 0,62$) e MLP ($0,11 \rightarrow 0,41$). O número médio de atributos selecionados foi de 13, uma redução de aproximadamente 76% em relação aos atributos originais.

Entre os atributos identificados como mais importantes pelo GAWLL, destacam-se variáveis de localização do talhão (latitude e longitude), o genótipo e seu propósito, e variáveis de manejo fitossanitário como aplicações de herbicida, fungicida e inseticida, que apareceram entre os atributos selecionados na maioria dos modelos.




Figura 3: Interação média entre os atributos no modelo Floresta Aleatória

A figura 3 mostra a interação entre os atributos no modelo Floresta Aleatória, destacando-se interações como decêndio de semeadura e altitude máxima (0.002) e número de dias com umidade relativa média < 60% e fotoperíodo (0.002).

Conclusões

Os resultados mostram que grande parte dos atributos originais tem pouca contribuição para a predição da produtividade, e que os modelos treinados apenas com os atributos selecionados pelo GAWLL não só mantiveram, como superaram o desempenho obtido com o conjunto completo de variáveis. Isso sugere que o uso de todos os atributos pode induzir os modelos a erro, provavelmente pela presença de ruído ou de variáveis pouco informativas.

Agradecimentos

Agradeço ao Programa Institucional de Bolsas de Iniciação Científica (PIBIC) e à Universidade de São Paulo pelo apoio institucional, e ao Prof. Renato Tinós pela orientação ao longo do desenvolvimento deste projeto.

Referências

- [1] TINÓS, R. et al. (2025). "Learning Variable Importance and Interaction in Genetic Algorithms". Submetido à Evolutionary Computation.
- [2] AZEVEDO, L. R. de. Predição de produtividade da soja a partir de dados de clima e índices de vegetação via aprendizado de máquina. Dissertação (mestrado), UNICAMP, 2025.
- [3] GUIMARÃES, D. G. et al. (2026). "Estimating Variable Importance and Interaction in Machine Learning via Genetic Algorithms". In: Intelligent Systems (BRACIS 2025). Lecture Notes in Computer Science, vol. 16179, Springer, Cham, pp. 478–492.